

Explicação/ Detalhes - Árvore de decisão

Código feito em Python pela ferramenta Google Collab.

Bibliotecas/pacotes utilizados:

- pandas para manipulação de dados;
- scikit-learn para criação e avaliação do modelo de árvore de decisão;
- matplotlib para visualização dos resultados;
- gdown para baixar o arquivo de dados diretamente do Google Drive.

Valores NA foram retirados.

Foram retirados também os sábados e domingos, já que a previsão será apenas de dias de semana.

As variáveis 'tipo refeicao', 'restaurante utilizado', 'categoria padrao', 'categoria vegano', 'dia_semana', 'mes', 'almoco', 'periodo semestre', 'feriado_dummy' (I) foram utilizadas como valores de entrada, features, parâmetros para a previsão.

O valor previsto é a 'quantidade'.

Os dados foram separados e cada observação diferente foi transformada em dummy (uma coluna para cada cardápio padrão, uma para cada cardápio vegano etc)

Ficamos com 1920 observações

Utilizamos a função 'train_test_split' para dividir os dados entre treino e teste em 80% e 20%.

Já para o modelo de árvore de decisão de fato os parâmetros utilizados foram:

Criterion = 'squared error': define a função usada para medir a qualidade da divisão dos nós. O "squared error" minimiza o erro quadrático médio, priorizando previsões mais próximas dos valores reais.

max_depth = 20 limita a profundidade máxima da árvore. Esse parâmetro é importante para evitar o overfitting, ou seja, quando o modelo aprende detalhes demais dos dados de treino e perde capacidade de generalização.

test_size = 0.2, controla quanto dos dados será usado para teste, nesse caso 20%

random_state = 42, garante que os resultados sejam reprodutíveis, mantendo o mesmo padrão de divisão dos dados e da estrutura da árvore em cada execução.

Após o treinamento, o modelo é avaliado com métricas como:

- Erro Absoluto Médio (MAE) = 240.0602, que mostra o quanto as previsões se desviam em média dos valores reais;
- R^2 (coeficiente de determinação) = 0.9029, que indica o quanto da variação da variável-alvo é explicada pelo modelo.

Para fazer a previsão oficial é necessário preencher a tabela "dados-previsaoPartell" com as observações faltantes (menos a coluna quantidade, obviamente).

A previsão a partir do cardápio recebida se iniciou com uma planilha com as colunas sendo as mesmas citadas em (I), a partir disso houve o mesmo processamento para transformar

em variáveis dummy, garantimos que as colunas fossem as mesmas do treino e a ordem delas também fosse igual.

O print ao final apresenta o restaurante utilizado, dia da semana e a quantidade prevista, lembrando que estão em ordem RU, RA, RS do almoço e RU, RA, RS da janta a cada dia da semana

Todos os códigos, tabelas e dados usados estão no drive, na pasta da disciplina.

Explicação/ Detalhes - Regressão com Binomial Negativa

Código feito em R pela ferramenta Google Collab.

Bibliotecas/pacotes utilizados:

- tidyverse
- MASS

Informações:

- Os valores NA , os sábados e domingos foram retirados, já que a previsão será apenas de dias de semana.
- As variáveis 'tipo_refeicao', 'restaurante_utilizado', 'categoria_padrao', 'categoria_vegano', 'dia_semana', 'mes', 'almoco', 'periodo_semester', 'feriado_dummy' (l) foram utilizadas como valores de entrada, features, parâmetros para a previsão.
- O valor previsto é a 'quantidade'.

Pensamos em ajustar um modelo de regressão, como a nossa variavel resposta é a quantidade de pessoas que comem no bandejão vamos ajustar um modelo de regressão para dados de contagem.

Geralmente o primeiro modelo ajustado para dados de contagem é Regressão de Poisson. No entanto, ao ajustar o modelo observamos que o modelo apresenta superdispersão, que ocorre quando a variância é maior que a média.

Para corrigir isso escolhemos o modelo de Regressão Binomial Negativa.

Este modelo é uma alternativa robusta, pois introduz um parâmetro de dispersão que acomoda a variabilidade extra presente nos dados. A Regressão Binomial Negativa pode ser derivada de uma mistura das distribuições Poisson e Gama. Assume-se que a contagem de refeições segue uma distribuição de Poisson, mas que sua média varia segundo uma distribuição Gama, capturando a heterogeneidade não observada.

A relação entre a média (μ_i) e a variância no modelo Binomial Negativo é dada por:

$$\text{Var}(Y_i) = \mu_i + \frac{1}{v} \mu_i^2 = \mu_i + D \mu_i^2$$

Onde $\sigma^2 = (1/v)\sigma$ é o parâmetro de dispersão. Note que quando $\sigma^2 \rightarrow 0$, a variância se aproxima da média, e o modelo Binomial Negativo converge para um modelo de Poisson.

Assim, ajustou-se o seguinte modelo de Regressão Binomial Negativa, utilizando a função de ligação logarítmica, que é a mais comum para esta família:

$$\log(\mu_i) = \beta_0 + \beta_1(\text{almoco})_i + \beta_2(\text{restaurante_utilizado})_i + \beta_3(\text{categoria_padrao})_i + \beta_4(\text{categoria_vegano})_i + \beta_5(\text{dia_semana})_i + \beta_6(\text{periodo_semestre})_i + \beta_7(\text{feriado_dummy})_i$$

Em que μ_i representa a quantidade esperada de refeições servidas.

RESULTADOS:

Coefficients:									
	Estimate	Std. Error	z value	Pr(> z)					
(Intercept)	5.28348	0.18053	29.266	< 2e-16	(Intercept)				***
almoco1	0.76565	0.03636	21.057	< 2e-16	almoco1				***
restaurante_utilizadoRS	0.02668	0.04876	0.546	0.58548	restaurante_utilizadoRS				
restaurante_utilizadoRU	1.21706	0.05034	24.176	< 2e-16	restaurante_utilizadoRU				***
categoria_padraobovino_suino	-0.02157	0.15752	-0.137	0.89110	categoria_padraobovino_suino				
categoria_padraofrango	0.09359	0.04324	2.164	0.03044	categoria_padraofrango				*
categoria_padraoOutros	-0.18038	0.20579	-0.877	0.38074	categoria_padraoOutros				
categoria_padraoovo	-0.61128	0.28990	-2.108	0.03500	categoria_padraoovo				*
categoria_padraopeixe	-0.60524	0.07536	-8.032	9.63e-16	categoria_padraopeixe				***
categoria_padraosuino	0.04988	0.05283	0.944	0.34507	categoria_padraosuino				
categoria_veganopts_proteina_texturizada	0.12239	0.04403	2.779	0.00545	categoria_veganopts_proteina_texturizada				**
categoria_veganovegetais	0.08520	0.14091	0.605	0.54544	categoria_veganovegetais				
dia_semanaqua	0.47056	0.17444	2.698	0.00699	dia_semanaqua				**
dia_semanaqui	0.37974	0.17760	2.138	0.03250	dia_semanaqui				*
dia_semanasáb	0.38419	0.17717	2.168	0.03012	dia_semanasáb				*
dia_semanaseg	0.36450	0.17799	2.048	0.04057	dia_semanaseg				*
dia_semanasex	0.20090	0.17749	1.132	0.25769	dia_semanasex				
dia_semanater	0.40414	0.17810	2.269	0.02326	dia_semanater				*
periodo_semestrefim	0.36466	0.04523	8.063	7.47e-16	periodo_semestrefim				***
periodo_semestreinicio	0.54105	0.06568	8.238	< 2e-16	periodo_semestreinicio				***
periodo_semestreneio	0.31442	0.07069	4.448	8.67e-06	periodo_semestreneio				***
feriado_dummy	0.37738	0.05447	6.928	4.26e-12	feriado_dummy				***

```

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(13.4449) family taken to be 1)

Null deviance: 1717.47 on 244 degrees of freedom
Residual deviance: 248.66 on 223 degrees of freedom
AIC: 3400.7

Number of Fisher Scoring iterations: 1

      Theta: 13.44
    Std. Err.: 1.23

2 x log-likelihood: -3354.666

```

Primeiramente, os dados foram divididos em dois conjuntos, um para treino e outro para teste. Isso foi feito criando um vetor de índices que atribuiu aleatoriamente 80% das observações ao grupo de treino e 20% ao grupo de teste. Em seguida, o modelo de regressão binomial negativa foi treinado utilizando exclusivamente o conjunto de dados de treino.

Após o treinamento, o modelo foi utilizado para gerar previsões sobre o conjunto de dados de teste, que o modelo não havia "visto" durante o treinamento. Nessa etapa, chegamos às seguintes métricas:

- MAE: 207.8943

- Pseudo R^2 de Nagelkerke: 0.8707

O pseudo R^2 é um índice que busca capturar a qualidade do ajuste, embora não seja equivalente ao coeficiente de determinação tradicional da regressão linear. Especificamente o R^2 de Nagelkerke é uma versão ajustada do índice de Cox e Snell, escalonada para ter um intervalo entre 0 e 1, e foi calculado usando o pacote DescTools do R.

Após o teste, foi ajustado um modelo completo com todas as linhas do banco de dados. A partir desse modelo, foram feitas as previsões finais desejadas.

REFERÊNCIA:

- <https://analises-ecologicas.com/cap8>

-

- <https://stats.stackexchange.com/questions/108995/interpreting-residual-and-null-deviance-in-glm-r>