

Como foi feita a limpeza do banco de dados:

Passos:

- Importação dos bancos de dados:
 - banco 1:
 - Variáveis: date, refeicao, acompanhamento, prato, guarnicao, opcao_vegetal, salada, sobremesa, suco.
 - banco 2:
 - Variáveis:

Primeiramente, trabalhamos apenas com o banco 1:

- Foram selecionadas apenas as variáveis relevantes para a análise: data da refeição (date), tipo de refeição (refeicao) e nome do prato (prato).
- A coluna de data foi convertida para o formato adequado (Date).
- Foram criadas duas variáveis adicionais:
 - Tipo de refeição: classificada como “Almoço” ou “Jantar”.
 - Tipo de cardápio: classificada como “Padrão” ou “Vegano”.
- Filtro das datas entre o início do primeiro semestre de 2024 (28/02/2024) e o final do segundo semestre de 2025 (12/07/2025).

Para facilitar a limpeza dividimos o banco em três partes: pratos Veganos e pratos Padrão e pratos com menos de 4 vezes de frequência (seriam os pratos que estão fora do padrão Veg/Pad -almoço e Veg/Pad - janta). O mesmo processo foi feito para cada banco mas com as suas particularidades:

- Tratamento de nomes dos pratos:
- Pratos com indicação de restaurante (RA, RS ou RU) tiveram o nome do prato limpo e o restaurante extraído.
- Pratos sem indicação de restaurante foram mantidos sem alterações.
- Algumas inconsistências foram corrigidas manualmente com base em um arquivo de correção externo.
- Foram criadas colunas binárias indicando em quais restaurantes o prato estava disponível: RU,RA,RS ou outro (para casos especiais como CAISM e HC).(no caso do <4 foram feitos apenas para o RS pois eram todos valores de sábado)
- Depois classificamos os pratos por categoria
 - Vegano: pratos classificados em proteína texturizada, leguminosas, cereais integrais, vegetais, feijoada vegana ou outros.
 - Padrão: pratos classificados em frango, bovino, peixe, suíno, bovino/suíno, feijoada, ovo ou outros.
- As colunas de restaurantes (RU, RA, RS) foram convertidas para uma coluna única indicando o restaurante utilizado, e contagens de registros por data foram adicionadas.
- Os bancos de dados de pratos veganos, padrões e inconsistentes foram unidos, formando um único banco limpo. As colunas finais selecionadas foram: data, tipo de refeição, restaurante utilizado e categorias de prato.
- Foram adicionadas variáveis para:
 - Dia da semana.

- Mês.
- Indicador binário de almoço.
- Período do semestre (início, meio, fim ou férias).
- O banco de volumetria de refeições foi lido e transformado para o formato longo, sendo unido ao banco principal para incluir a quantidade de refeições servidas por data e restaurante. (A limpeza anterior deste foi outra pessoa q fez e acho q foi pelo excell mesmo)

```
> glimpse(dados)
```

```
Rows: 2,512
```

```
Columns: 10
```

```
$ date          <date> 2024-02-28, 2024-02-28, 2024-02-28, 2024-02-28, 2...
```

```
$ tipo_refeicao   <fct> Almoço, Almoço, Almoço, Jantar, Jantar, Jantar, Al...
```

```
$ restaurante_utilizado <fct> RU, RA, RS, RU, RA, RS, RU, RA, RS, RU, RA, RS, RU...
```

```
$ categoria_padrao <fct> bovino, bovino, bovino, bovino_suino, bovino_suino...
```

```
$ categoria_vegano <fct> leguminosas, leguminosas, leguminosas, leguminosas...
```

```
$ dia_semana     <fct> qua, qua, qua, qua, qua, qua, qua, qui, qui, qui, ...
```

```
$ mes           <fct> fev, fev, fev, fev, fev, fev, fev, fev, fev, fev, ...
```

```
$ almoco        <fct> 1, 1, 1, 0, 0, 0, 1, 1, 1, 0, 0, 0, 1, 1, 1, 0, 0,...
```

```
$ periodo_semestre <fct> inicio, inicio, inicio, inicio, inicio, inicio, in...
```

```
$ quantidade     <dbl> 4112, 1155, 1384, 2200, 559, 386, 3708, 1253, 1364...
```

```
# A tibble: 5 × 10
```

```
  date      tipo_refeicao restaurante_utilizado categoria_padrao categoria_vegano
dia_semana mes  almoco periodo_semestre quantidade
  <date>    <fct>    <fct>          <fct>          <fct>      <fct> <fct> <fct>
<dbl>
1 2024-02-28 Almoço    RU            bovino      leguminosas  qua      fev  1
  inicio      4112
2 2024-02-28 Almoço    RA            bovino      leguminosas  qua      fev  1
  inicio      1155
3 2024-02-28 Almoço    RS            bovino      leguminosas  qua      fev  1
  inicio      1384
4 2024-02-28 Jantar    RU            bovino_suino leguminosas  qua      fev  0
  inicio      2200
5 2024-02-28 Jantar    RA            bovino_suino leguminosas  qua      fev  0
  inicio      559
>
```

Análise de dados vazios e faltantes

VAZIO

Temos 4 valores que tem a quantidade zerada no banco de dados original os dias:
28/01/2025 ; 26/04/2025; 05/07/2025 e 12/07/2025

```
> summary(zeroos)
  date      tipo_refeicao restaurante_utilizado categoria_padrao categoria_vegano dia_semana  mes almoco
Min.   :2025-01-28  Almoço:0      RA:1      bovino      :4  cereais_integrais  :0  dom:0  jul   :2  0:4
1st Qu.:2025-04-04  Jantar:4      RS:1      bovino_suino:0  feijoad_vegana    :0  qua:0  abr   :1  1:0
Median :2025-05-31                RU:2      feijoad    :0  leguminosas      :3  qui:0  jan   :1
Mean   :2025-05-10                frango      :0  Outros         :0  sáb:3  ago   :0
3rd Qu.:2025-07-06                Outros      :0  pts_proteina_texturizada:1  seg:0  dez   :0
Max.   :2025-07-12                ovo         :0  vegetais       :0  sex:0  fev   :0
                                (Other) :0  ter:1  (Other):0

período_semestre quantidade
ferias:1      Min.   :0
fim   :2      1st Qu.:0
início:0      Median :0
meio  :1      Mean   :0
                                3rd Qu.:0
                                Max.   :0
```

NA:
Filtrando o banco para mostrar apenas os valores NA para quantidadetemos 380 valores:

Desses 99 dias tem valores NA

```
> summary(vaziooooo)
  date      tipo_refeicao restaurante_utilizado categoria_padrao categoria_vegano dia_semana  mes almoco
Min.   :2024-04-06  Almoço:192  RA:188      bovino      :150  cereais_integrais  : 6  dom: 3  jan   : 71  0:188
1st Qu.:2024-08-24  Jantar:188  RS: 21      frango     :113  feijoad_vegana    : 0  qua: 32  mai   : 44  1:192
Median :2025-01-02                RU:171      peixe      : 57  leguminosas      :252  qui: 20  abr   : 40
Mean   :2024-12-04                suíno      : 51  Outros         : 2  sáb:252  jun   : 40
3rd Qu.:2025-03-04                ovo        : 8  pts_proteina_texturizada:114  seg: 28  jul   : 32
Max.   :2025-07-12                (Other): 0  vegetais       : 6  sex: 29  mar   : 32
                                NA's    : 1  ter: 16  (Other):121

período_semestre quantidade
ferias:129      Min.   : NA
fim   :103      1st Qu.: NA
início: 60      Median : NA
meio  : 88      Mean   :NaN
                                3rd Qu.: NA
                                Max.   : NA
                                NA's    :380
```