

Desperdício alimentar e aprendizado de máquina: utilizando modelos para predição de demanda diária nos restaurantes universitários da Unicamp

Amanda Montezano de Almeida
Estatística
Universidade Estadual de Campinas
204207

Luiza Bernardi da Silva
Estatística
Universidade Estadual de Campinas
236218

Sofia Moreira Marinho
Estatística
Universidade Estadual de Campinas
236305

Ana Beatriz Rodrigues Carvalho
Matemática Aplicada e Computacional
Universidade Estadual de Campinas
238029

Guilherme Duarte Alves Basso
Estatística
Universidade Estadual de Campinas
240805

Marcus Vinícius Pimenta Soares
Matemática Aplicada e Computacional
Universidade Estadual de Campinas
297346

Daniela Cielo Cuadrao Pérez
Estatística
Universidade Estadual de Campinas
298825

Abstract—O presente trabalho tem por objetivo analisar e prever a demanda diária, via técnicas de aprendizado de máquina, dos restaurantes universitários da Universidade Estadual de Campinas, a fim de oferecer alternativas eficientes para redução do desperdício alimentar.

A análise preliminar evidencia que, no início do semestre, o número de refeições servidas (almoço e jantar) é significativamente maior em comparação ao final do período letivo. Para modelar essa variação temporal, foram implementados dois algoritmos de aprendizado supervisionado: Árvore de Decisão e Regressão Binomial Negativa. De forma geral, ambos os modelos apresentaram desempenho satisfatório, com bons valores do erro médio absoluto e coeficiente de determinação, capturando adequadamente o comportamento padrão do consumo ao longo da semana.

Aliado a isso, o algoritmo *K-Prototypes* foi utilizado para identificação de clusters representativos no banco de dados, onde foram obtidos 6 clusters que posteriormente foram agregados ao banco de dados e analisados juntamente com as outras variáveis presentes, incorporando uma abordagem via aprendizado de máquina não supervisionado.

Palavras-chave—Aprendizado de máquina, Regressão Binomial Negativa, Árvore de Decisão, *K-Prototypes*, dados.

I. INTRODUÇÃO

Um dos principais desafios enfrentados pelos restaurantes universitários é o controle da quantidade de alimentos produzidos e armazenados, tarefa que exige fiscalização rigorosa para evitar desperdícios e garantir a qualidade das refeições servidas. De acordo com a *Food and Agriculture Organization of the United Nations (FAO, 2013)*, cerca de 1,3 bilhão de toneladas de alimentos são descartados anualmente no mundo. Desse total, aproximadamente 350 milhões de toneladas correspondem ao desperdício na etapa de consumo, sendo que o

setor de alimentação coletiva é responsável por 15% a 20% [1]. No Brasil, a situação é igualmente alarmante: segundo a ONU, são desperdiçadas 46 milhões de toneladas de alimentos por ano [2], [3].

Esse panorama reflete-se também nos restaurantes universitários, onde o desperdício pode estar associado a diferentes fatores, tais como falta de conscientização dos consumidores, problemas de gestão interna das empresas responsáveis pelo preparo das refeições, deficiências na divulgação dos cardápios ou ainda falhas na previsão de demanda, influenciada por condições externas. Diversas abordagens podem ser empregadas para mitigar tais problemas, incluindo políticas de conscientização e educação alimentar, melhoria nos processos logísticos e de gestão, além de soluções computacionais baseadas em análise de dados e aprendizado de máquina, capazes de auxiliar na previsão da demanda e no planejamento de produção.

Verificou-se que o estágio do semestre letivo (início, meio ou fim) exerce influência significativa sobre o volume de refeições servidas. Essa constatação evidencia a relevância de desenvolver modelos preditivos capazes de incorporar flutuações temporais.

O comportamento acima é evidenciado por meio do Gráfico 1, seguido da explicação de como as variáveis temporais foram operacionalizadas no banco de dados presente, utilizando uma convenção de segmentação temporal.

II. METODOLOGIA




Gráfico 1. Comportamento do consumo no período de Fevereiro de 2024 a Julho de 2025

- **Início:** corresponde ao primeiro dia de aula do período letivo, conforme estabelecido pelo calendário acadêmico da Unicamp;
- **Meio:** etapa intermediária, calculada mediante a divisão do total de dias letivos em três partes iguais;
- **Fim:** definido como o último dia do período letivo, também com base no calendário acadêmico.

Nos casos em que a divisão não resultou em um número inteiro de dias, a fase final foi atribuída com a maior quantidade de dias, justificada pela expressiva redução no consumo observada nesse período. A distribuição resultante encontra-se detalhada na Tabela 1.

TABELA 1
DIAS ATRIBUÍDOS A CADA CLASSIFICAÇÃO

Semestre	Início (Dias)	Meio (Dias)	Fim (Dias)	Total (Dias)
1s2024	43	43	43	129
2s2024	42	42	44	128
1s2025	46	46	46	138

Neste contexto, o presente artigo desenvolvido propõe prever a demanda diária nos Restaurantes Universitários da Universidade Estadual de Campinas por meio de técnicas de Aprendizado de Máquina, buscando auxiliar em um planejamento eficiente e, consequentemente, na redução do desperdício alimentar. Foram utilizados dois modelos de aprendizado de máquina supervisionado: Árvore de Decisão e Regressão Binomial Negativa e além disso, o modelo de aprendizado não supervisionado *K-Prototypes* também foi implementado.

O presente artigo segue a seguinte organização: na seção II é discutida a metodologia utilizada durante o estudo, bem como o banco de dados é tratado e validado; nas seções III e IV são apresentados, respectivamente, os modelos de aprendizado supervisionado e o modelo de aprendizado não supervisionado e a forma como foram trabalhados, analisados e aplicados; após isso, os resultados do trabalho são apresentados na seção V; nas seções VI e VII são feitos, respectivamente, as conclusões obtidas e os agradecimentos, por fim, na seção VIII, é explicado o uso de inteligência artificial neste trabalho.

Para a limpeza e manipulação dos dados, assim como a aplicação dos modelos de Aprendizado de Máquina, foram utilizados as ferramentas Excel, Python (pacotes utilizados: *pandas*, 2.3.3; *scikit-learn*, 1.7.2; *matplotlib*, 3.10.7; *gdown*, 5.2.0; *numpy*, 2.3.5; *seaborn*, 0.13.2; *statsmodels*, 0.14.5) e R (pacotes utilizados: *tidyverse*, 2.0.0; *readxl*, 1.4.5; *purrr*, 1.2.0; *scales*, 1.4.0; *clustMixType*, 0.4-2; *DescTools*, 0.99.60). A base de dados utilizada foi construída a partir de informações disponibilizadas pela Prefeitura Universitária da Unicamp, que forneceu duas planilhas em formato Excel, sendo uma contendo os cardápios diários e outra com o registro do número de usuários que acessaram os restaurantes universitários da instituição, a saber, RU (Restaurante Universitário), RA (Restaurante Administrativo) e RS (Restaurante Saturnino).

Para possibilitar o cruzamento das informações, foram considerados os registros compreendidos entre o início do período letivo, em 28/02/2024, e o término do primeiro semestre de 2025, em 12/07/2025. Esse recorte garante a disponibilidade consistente de dados tanto sobre os cardápios quanto sobre o volume de refeições servidas.

Durante a etapa de limpeza e estruturação, identificaram-se e corrigiram-se inconsistências relacionadas a valores ausentes, padronização de nomes de pratos e diferenças entre restaurantes em um mesmo dia. Foram removidos os registros referentes a finais de semana e feriados, períodos em que o funcionamento não é regular. Após o tratamento, os bancos referentes aos cardápios padrão e vegano foram integrados, originando uma única base de dados consolidada e pronta para a aplicação dos modelos de aprendizado supervisionado e não supervisionado.

A. Banco de dados

A Tabela 2 apresenta as categorias de proteína utilizadas nos cardápios padrão e suas respectivas frequências. Essas categorias foram definidas a partir da ocorrência de palavras-chave no nome do prato principal, permitindo a classificação automática do tipo de proteína oferecida.

TABELA 2
DESCRIÇÃO DAS CATEGORIAS DE PROTEÍNA PADRÃO E SUAS QUANTIDADES

Categoria Padrão	Informação	Quantidade
Bovino	"boi", "bovino", "bife", "carne", "lagarto", "iscas bovinas", "ácem", "patinho", "almôndega"	1061
Frango	"frango", "sobrecoca", "nugget"	747
Suíno	"suíno", "bisteca", "suína", "pernil", "linguiça toscana", "copa lombo"	347
Peixe	"peixe", "tilápia", "pescada"	274
Feijoada	"feijoada"	48
Ovo	"fritada", "omelete"	15
Bovino e Suíno	"bovinos e suínos", "salsicha"	13
Outros		5

De maneira análoga, a Tabela 3 apresenta as categorias de proteína do cardápio vegano e a frequência com que cada uma foi oferecida no período analisado.

TABELA 3
DESCRIÇÃO DAS CATEGORIAS DE PROTEÍNA VEGANA E SUAS QUANTIDADES

Categoria Vegana	Informação	Quantidade
Leguminosas	"feijão", "lentilha", "grão-de-bico", "ervilha", "soja", "grão de bico", "feijão branco", "fradinho", "mix de feijões", "leililha"	1740
Proteína Texturizada	"pts", "proteína texturizada", "almôndega vegana", "stroganoff vegano", "quibe de pts", "fricassê de pts", "fricassê vegano"	709
Vegetais	"quibe de abóbora", "quibe de brócolis"	29
Cereais Integrais	"arroz integral", "quinoa", "aveia", "trigo", "cevada", "milho", "arroz 7 grãos", "cuscuz", "cuzcuz"	15
Feijoada Vegana	"feijoada vegana"	12
Outros		7

As variáveis presentes no banco final estão apresentadas na Tabela 4. As variáveis categóricas foram transformadas em fatores (fct) e as quantitativas armazenadas como números reais (dbl), conforme padrão adotado para o pré-processamento dos modelos.

TABELA 4
VARIÁVEIS DO BANCO E SEUS TIPOS

Variável	Tipo	Descrição
Data	date	Data da observação
Tipo Refeição	fct	Almoço ou jantar
Restaurante Utilizado	fct	RU, RA ou RS
Categoria Padrão	fct	Tipo de proteína principal (bovino, frango, etc.)
Categoria Vegano	fct	Tipo de proteína principal (leguminosas, PTS, etc.)
Dia da Semana	fct	Segunda a sexta-feira
Mês	fct	Mês correspondente à data
Almoço	fct	Indicador binário para refeição
Período Semestre	fct	Início, meio ou fim do semestre
Quantidade	dbl	Número de refeições servidas

Após essas etapas, obteve-se um banco consolidado, livre de inconsistências e com as variáveis devidamente estruturadas para a modelagem.

Feito isso, foram aplicadas técnicas de aprendizado de máquina supervisionado com o objetivo de prever a quantidade de refeições servidas nos restaurantes universitários da Unicamp. Foram implementados dois modelos distintos, a comparação entre esses métodos permite avaliar o desempenho de algoritmos de naturezas diferentes, considerando critérios de precisão e interpretabilidade.

B. Validação do banco de dados

Com o banco de dados limpo e consolidado, foram aplicados testes estatísticos para aferir a validação do banco e posteriormente utilizá-lo como o banco base para os modelos previstos.

Considerando o Gráfico 2, observa-se que, independente do período, o almoço é a refeição que apresenta a maior

demanda. Observa-se também que, ao decorrer do semestre existe uma queda do número de refeições servidas, o que motiva o escopo deste artigo, visto que é necessário que haja quantidade suficiente de comida no início e que não se desperdice alimento no fim do semestre.




Gráfico 2. Mapa de calor da média de refeições por período do semestre

Com isso, iniciou-se uma análise mais descritiva dos dados, onde notou-se também uma diferença entre a quantidade de refeições servidas por cada restaurante. Sendo assim, foi ajustado um modelo estatístico de Planejamento por Blocos Completos a fim de verificar como essa diferença se comportava. Como o interesse do trabalho é no efeito do início, meio e fim do semestre letivo, os restaurantes foram utilizados como variável de controle. Assim, foi considerado o modelo:

$$Y_{ij} = \mu + \alpha_i + \tau_j + \xi_{ij}, \quad \xi_{ij} \sim \text{i.i.d. } N(0, \sigma^2) \quad (1)$$

onde:

- Y_{ij} : número de refeições servidas no restaurante j durante o período i ;
- μ : média do número de refeições
- α_i : efeito fixo do período do semestre (i = início, meio, fim, férias);
- τ_j : efeito fixo do restaurante (j = RA, RS, RU);
- ξ_{ij} : erro aleatório independente e normalmente distribuído.

As restrições adotadas foram $\alpha_1 = \tau_1 = 0$, neste caso, o período das férias e o restaurante RA.

Com isso, foi possível organizar a Tabela 5 :

TABELA 5
ESTATÍSTICAS DESCRITIVAS POR PERÍODO DO SEMESTRE

Período do Semestre	Mínimo	Máximo	Mediana	Desvio Padrão
Início	157	4891	1387.0	1176.7991
Meio	245	5026	1308.0	1075.5751
Fim	138	6730	1219.5	1006.9290
Férias	4	2271	645.0	529.1186

Também foi realizada uma análise de variância (ANOVA) do modelo. Utilizando os fatores do período do semestre e do restaurante utilizado, verificou-se que ambos apresentam

efeito significativo sobre a quantidade de refeições servidas, com o teste F e o valor-p sendo $F = 229,85$; $p < 2.2 * 10^{-16}$ e $F = 1860,84$; $p < 2.2 * 10^{-16}$, respectivamente.

TABELA 6
COMPARAÇÃO MÚLTIPLA ENTRE OS PERÍODOS DO SEMESTRE

Comparação	Estatística F	p-valor
Meio vs Início	268.08	<0.001
Fim vs Início	588.31	<0.001
Férias vs Início	433.27	<0.001
Meio vs Fim	83.27	<0.001
Meio vs Férias	26.37	<0.001
Fim vs Férias	15.92	<0.001

A Tabela 6 é uma comparação múltipla entre os períodos do semestre, onde todas as comparações apresentam diferenças estatisticamente significativas. Ressalta-se que, como foram realizados vários testes de hipóteses, foi utilizado o ajuste de Bonferroni. Ainda vale destacar que o contraste entre início e fim do período é o mais expressivo, indicando um consumo significativamente maior no início do semestre.

III. APRENDIZADO DE MÁQUINA SUPERVISIONADO

A. Preparação dos dados

Inicialmente, foram removidos do banco de dados os valores ausentes (NA) e excluídos os registros referentes a sábados e domingos, pois o objetivo da previsão se restringia aos dias úteis.

Somado a isso, as variáveis consideradas como preditoras foram as seguintes: *tipo_refeicao*, *restaurante_utilizado*, *categoria_padrao*, *categoria_vegano*, *dia_semana*, *mes*, *periodo_semestre* e *feriado_dummy*. A variável-alvo é a *quantidade*, correspondente ao número de refeições servidas por dia.

Para a utilização dos modelos, as variáveis categóricas foram transformadas em variáveis do tipo dummy, gerando colunas binárias correspondentes a cada categoria. Após o processamento, o conjunto final apresentou 1.920 observações.

B. Árvore de Decisão

1) *Aspectos teóricos*: O modelo de Árvore de Decisão é uma técnica de aprendizado de máquina supervisionado que realiza divisões sucessivas no conjunto de dados, criando partições cada vez mais homogêneas em relação à variável de interesse. Cada nó representa uma condição sobre uma variável preditora e cada folha corresponde ao valor previsto.

O algoritmo busca particionar o espaço das variáveis de forma a minimizar uma medida de impureza, como o erro quadrático médio em problemas de regressão. O método apresenta boa interpretabilidade e é capaz de capturar relações não lineares entre as variáveis, porém pode sofrer de sobreajuste quando a profundidade da árvore é excessiva, exigindo controle de parâmetros para garantir boa generalização.

2) *Aplicação prática*: O modelo foi implementado em Python, utilizando o ambiente Google Colab. As bibliotecas empregadas foram *pandas* para manipulação de dados, *scikit-learn* para criação e avaliação do modelo, *matplotlib* para visualização dos resultados e *gdown* para importação do arquivo de dados.

Para a previsão final, utilizou-se o conjunto de dados exceto a coluna de quantidade. O conjunto passou pelo mesmo processo de codificação dummy, garantindo correspondência entre as colunas do treino e da previsão. O modelo estimou a demanda diária de refeições para cada restaurante (RU, RA e RS) e refeição (almoço e jantar) nos dias úteis.

C. Regressão Binomial Negativa

1) *Aspectos teóricos*: O número de pessoas que frequentam os restaurantes universitários foi modelado por meio de um Modelo Linear Generalizado com distribuição Binomial Negativa, escolhido por lidar adequadamente com variáveis de contagem que apresentam superdispersão, ou seja, quando a variância supera a média, situação em que o modelo de Poisson se torna inadequado. De forma geral, o preditor linear do modelo é definido como

$$\eta_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} \quad (2)$$

em que x_{ij} representa a j -ésima covariável da observação i .

É adotada a suposição de que a variável resposta Y_i segue uma distribuição Binomial Negativa com média μ_i e parâmetro de dispersão θ , cuja função de probabilidade é

$$P(Y_i = y_i) = \frac{\Gamma(y_i + \theta)}{\Gamma(\theta) y_i!} \left(\frac{\mu_i}{\mu_i + \theta} \right)^{y_i} \left(\frac{\theta}{\mu_i + \theta} \right)^{\theta}, y_i = 0, 1, \dots \quad (3)$$

Os parâmetros β e θ foram estimados pelo método da máxima verossimilhança, e os coeficientes β_j são interpretados em termos de razões de taxas, por $\exp(\beta_j)$, que representa o fator multiplicativo na média da resposta associado a um aumento unitário em x_j , mantendo as demais covariáveis constantes. Uma discussão mais aprofundada sobre essa abordagem pode ser encontrada em Agresti (2006, p. 74-84).

2) *Aplicação prática*: O modelo de Regressão Binomial Negativa foi implementado em R, utilizando o ambiente Google Colab. As bibliotecas empregadas foram *tidyverse*, para manipulação e organização dos dados, e *MASS*, para o ajuste do modelo estatístico. O conjunto de dados utilizado foi o mesmo aplicado ao modelo de árvore de decisão.

A análise do modelo indicou que a variável referente ao tipo de refeição almoço possui coeficiente positivo e significativo, evidenciando aumento substancial na quantidade esperada de refeições quando comparada ao jantar. De forma semelhante, os restaurantes RS e, sobretudo, RU apresentaram efeitos positivos significativos em relação ao restaurante de referência (RA). Algumas categorias do cardápio padrão, como feijoada, frango e suíno, também exibiram coeficientes positivos, sugerindo que esses pratos estão associados a maior demanda em relação a categoria bovino (referência).

Em contraste, certas categorias do cardápio vegano apresentaram coeficientes negativos e significativos, como leguminosas, proteína texturizada, vegetais e a categoria Outros. Esses resultados indicam redução na quantidade esperada de refeições em comparação à categoria de referência. Entre todas as categorias, o prato peixe apresentou a maior redução, sendo o coeficiente negativo mais expressivo do modelo.

No que se refere às variáveis de dia da semana, segunda, terça, quarta e quinta-feira apresentaram efeitos positivos significativos, enquanto sexta-feira apresentou coeficiente negativo significativo. O dia de sábado não apresentou significância estatística. As fases do semestre, início, meio e fim, mostraram-se todas significativas e positivas.

Por outro lado, algumas variáveis não apresentaram significância estatística no modelo, como as categorias bovino/suino, ovo e Outros no cardápio padrão, a categoria vegana feijoadada, o indicador de feriado e o dia de sábado.

Para avaliar a demanda individual de cada restaurante, ajustou-se também um modelo de Regressão Binomial Negativa incluindo um termo de offset referente ao logaritmo do número de lugares disponíveis em cada restaurante. O objetivo é modelar a quantidade média de refeições por restaurante, permitindo comparar restaurantes de tamanhos distintos em uma base proporcional. Dessa forma, o modelo passa a estimar efeitos relativos, a demanda, corrigindo a influência estrutural do tamanho máximo de atendimento.

Enquanto no modelo sem offset os restaurantes RS e RU apresentaram coeficientes positivos (indicando maior demanda absoluta), no modelo com offset os coeficientes tornam-se negativos, refletindo que, quando ajustada a capacidade, a taxa de refeições realizadas por lugar é menor em RS e RU quando comparada ao restaurante de referência (RA). Esse comportamento era esperado, pois RU e RS possuem capacidade significativamente maior, e o offset corrige esse efeito estrutural.

As demais variáveis tiveram um comportamento semelhante ao modelo sem offset.

D. Treinamento e teste

Para realizar o treinamento do modelo de árvore de decisões, os dados foram separados a partir de uma semente para garantir reprodutibilidade em quatro variáveis: X_{test} , Y_{test} , X_{train} e Y_{train} . Para essa separação, 80% do banco de dados total foi reservado ao treino (variáveis X_{train} e Y_{train}) e os 20% restantes foram alocados às variáveis de teste (X_{test} e Y_{test}). Como abordado anteriormente, a variável de interesse é a quantidade de pessoas (*quantidade*), portanto os dados desta foram alocados à variável Y, e os dados das variáveis *tipo_refeicao*, *restaurante_utilizado*, *categoria_padrao*, *categoria_vegano*, *dia_semana*, *mes*, *periodo_semestre*, *feriado_dummy* foram alocados de forma vetorial à variável X.

Assim, uma vez definidos os dados de treino e teste, o modelo foi treinado com profundidade 20 (*max_depth*) com as variáveis X_{train} e Y_{train} . Em seguida, o X_{test} foi

utilizado para realizar a previsão da variável de interesse, nomeada de Y_{prev} .

Cabe ressaltar que tal escolha da profundidade da árvore se deu após testes no modelo. Constatou-se que, para o valor de profundidade igual a 15, o modelo apresentou os valores 67.865 e 0.982, correspondentes ao erro absoluto médio (MAE) e do coeficiente de determinação (R^2), respectivamente. Conforme o valor atribuído à profundidade aumentou, houve uma diminuição no valor do MAE e um aumento no R^2 , o que é um sinal de melhora no modelo. A partir do valor 25, tais métricas de avaliação mostraram uma diferença para os valores sequenciais na casa de 10^{-5} . Portanto, a fim de evitar *overfitting* no modelo, o valor escolhido foi o de 20, que para os parâmetros de treino, durante o treinamento, apresentou os valores $R^2 = 0.988$ e $MAE = 46.162$.




Gráfico 3. Comparação dos valores reais vs os valores obtidos pelo modelo da Árvore de Decisão durante o treinamento.

O Gráfico 3 apresenta a relação entre os valores reais e os valores previstos pelo modelo durante o treinamento, indicando que o modelo está bem ajustado. O ideal é que os pontos estejam próximos da linha vermelha, que representa a igualdade entre valores observados e estimados. Pontos acima dessa linha indicam superestimação, enquanto os pontos abaixo indicam subestimação. De modo geral, observa-se que o modelo apresenta um desempenho satisfatório, pois as previsões estão razoavelmente próximas dos valores reais.

O Gráfico 4 exemplifica quais *features* se mostraram mais importantes na hora da tomada de decisão. Observe que o restaurante que será servida a refeição é muito importante para a predição, assim como o tipo de refeição e se o período é de férias ou não.




Gráfico 4. Árvore de Decisão mostrando as *features* mais importantes.

Para realizar a avaliação do desempenho do modelo na etapa de predição, as métricas utilizadas também foram o MAE e o R^2 entre a variável prevista e a observação real (Y_{prev} e Y_{test}), cujos valores obtidos foram, aproximadamente:

- MAE: 238.49
- R^2 : 0.906

Embora o MAE esteja bom, ele não está ideal, dada a escala dos dados que estão sendo usados. No entanto, o coeficiente de determinação, que apresenta valores no intervalo de 0 a 1, indica um bom ajuste do modelo de árvore de decisões aos dados, dado que quanto mais próximo de 1 for o valor de R^2 , melhor está o algoritmo.

Já para o modelo de Regressão Binomial Negativa, também foi utilizada a mesma proporção de dados para treino e para teste, 80% e 20%, respectivamente. Além disso, as mesmas variáveis de interesse foram aplicadas ao modelo, e usadas para fazer as previsões dos dados de teste.

Os resultados do treinamento podem ser verificados no Gráfico 5, que assim como no Gráfico 3, mostra que o ajuste do modelo está adequado.




Gráfico 5. Comparação dos valores reais vs os valores obtidos pelo modelo de teste da Binomial Negativa

Para avaliar o desempenho na etapa de previsão, também foi utilizado o MAE, mas em adição, o Pseudo R^2 de Nagelkerke ganha espaço nesta análise, cujos valores obtidos foram

- MAE: 207.89

- Pseudo R^2 de Nagelkerke: 0.871

O pseudo R^2 é um índice que busca capturar a qualidade do ajuste, embora não seja equivalente ao coeficiente de determinação tradicional da regressão linear. Especificamente o R^2 de Nagelkerke é uma versão ajustada do índice de Cox e Snell, escalonada para ter um intervalo entre 0 e 1, e foi calculado usando o pacote *DescTools* do R.

Assim, pode-se inferir que, em relação ao modelo de árvore de decisões, este modelo tem maior acurácia ao analisarmos o MAE, no entanto a qualidade do ajuste é inferior.

IV. APRENDIZADO DE MÁQUINA NÃO SUPERVISIONADO

A. Preparação dos dados

Realizou-se a mesma etapa inicial de limpeza dos dados e a transformação das variáveis categóricas em variáveis dummy, conforme o procedimento adotado no método de aprendizado supervisionado. Para a etapa de clustering, foram removidas variáveis redundantes (date e almoco), de modo a evitar interferências desnecessárias na análise. Além disso, a variável quantidade, de natureza numérica, foi centralizada e escalonada, por meio do *Z-score*, garantindo que sua influência no processo de agrupamento fosse equilibrada em relação às demais variáveis. As observações com valores ausentes (NAs) foram removidas pelo algoritmo durante o processamento.

B. Algoritmo K-Prototypes

1) *Aspectos teóricos*: O algoritmo *K-means*, um dos mais utilizados para clusterização, porém o mesmo só aceita dados numéricos. Como o dataset de consumo dos RUs é composto por dados mistos foi necessário empregar uma variação robusta, o algoritmo *K-Prototypes*, que aceita tanto dados categóricos quanto numéricos. O *K-Prototypes* calcula a dissimilaridade total (ou função de custo) entre os dados, que deve ser minimizada para agrupar instâncias mais semelhantes dentro do mesmo cluster. Para dados mistos, o algoritmo utiliza uma métrica de dissimilaridade que combina as distâncias calculadas de formas diferentes para cada tipo de variável. Para as variáveis numéricas, é utilizada a distância euclidiana normalizada entre dois pontos, X e Y . Para as variáveis categóricas, a contribuição para a dissimilaridade é binária, indicando se os valores são iguais (0) ou diferentes (1). A dissimilaridade geral $d(X, Y)$ é calculada pela média ponderada dessas diferentes distâncias. O algoritmo utiliza um hiperparâmetro, frequentemente denotado como λ (ou γ no módulo *kmodes*). Este parâmetro pondera a influência dos dados numéricos em relação aos categóricos no cálculo da distância: se λ for maior, os dados numéricos terão maior influência na formação dos clusters.

2) *Aplicação prática*: Para determinar o número ótimo de clusters, foi utilizado o Método do Cotovelo (*Elbow Method*). Esse procedimento consiste no cálculo do *Total Within-Cluster Sum of Squares* (WSS), principal métrica de compactação dos grupos. O WSS representa a soma dos erros quadráticos, em que o erro total corresponde à soma das distâncias ao quadrado de cada ponto em relação ao centróide do seu respectivo cluster. O método baseia-se no princípio de que, à

medida que o número de clusters (K) aumenta, o WSS tende a diminuir, pois os dados são divididos em grupos menores e mais homogêneos. Entretanto, a partir de determinado ponto, esse ganho de compactação se torna marginal.




Gráfico 6. Método do cotovelo para o algoritmo *K-Prototypes*

A análise da curva do WSS em função de K (variando de 2 a 20) evidencia a tendência de redução da dissimilaridade interna, permitindo identificar o ponto de inflexão correspondente ao número mais adequado de clusters. No Gráfico 6, nota-se uma redução acentuada do WSS entre $K = 2$ e $K = 4$, indicando melhorias significativas na formação dos grupos. A partir de $K = 6$, contudo, a taxa de decréscimo torna-se menos expressiva, sugerindo que adicionar mais clusters não proporciona ganhos relevantes na coesão das partições, caracterizando, assim, o "cotovelo" do método.

V. RESULTADOS

A. Árvore de Decisões e Regressão Binomial Negativa

Para a etapa de aprendizado de máquina supervisionado, uma vez treinados os modelos, eles foram utilizados para realizar previsões do número de refeições servidas nos restaurantes universitários nos dias úteis da semana do dia 20 de outubro de 2025, a partir do cardápio previsto. Para tanto, foi utilizado um banco contendo informações sobre as variáveis que seriam utilizadas para a previsão.

Sendo assim, sob a suposição de que não haverão mudanças no cardápio, os resultados obtidos sobre a previsão da quantidade de refeições servidas nos três restaurantes universitários da Unicamp, separados por modelos, estão apresentados na Tabela 7:

TABELA 7
RESULTADO DAS PREVISÕES DOS MODELOS SUPERVISIONADOS

Dia da Semana	Total de Refeições		
	Árvore de Decisão	Binomial Negativa	Desvio Padrão
Segunda	10811	8237	1087.107
Terça	9464	8322	1123.219
Quarta	7392	5963	1144.907
Quinta	7610	7612	1114.698
Sexta	7153	6657	1021.575

Para uma comparação da previsão feita pelos modelos, a representação visual proposta, no Gráfico 7, exemplifica a diferença entre os resultados obtidos de cada modelo. Junto a ele, construiu-se o Gráfico 8, que representa o percentual da diferença absoluta entre a previsão de cada modelo, também separada por restaurante e refeição: como segue:




Gráfico 7. Quantidade prevista de refeições por modelo




Gráfico 8. Percentual da diferença absoluta da quantidade prevista entre os modelos

Ao analisar o Gráfico 7 e as tabelas com as previsões, é possível perceber que nos dois modelos de previsão, o RU concentra a maior quantidade de pessoas, e os outros dois restaurantes possuem quantidades bem menores, o que já era esperado, visto que o RU apresenta maior capacidade estrutural em relação aos outros restaurantes. Apesar da diferença volumétrica, a previsão realizada indica que o comportamento diário tende a ser parecido entre os dias da semana, com picos e vales em lugares similares em cada restaurante, por dia.

O Gráfico 8 foi construído de forma que, para cada dia da semana, restaurante e refeição, a observação foi calculada realizando a diferença absoluta entre a previsão de cada modelo, dividida pela média das quantidades previstas em cada modelo, ou seja:

$$dif = \left| \frac{Q_{arv} - Q_{reg}}{\frac{Q_{arv} + Q_{reg}}{2}} \right| \quad (4)$$

Onde Q_{arv} e Q_{reg} representam as quantidades previstas dos modelos de Árvore de Decisão e Regressão Binomial Negativa, respectivamente.

Assim, pode-se concluir que, apesar de existir um comportamento similar entre modelos, ainda existem pontos que se mostram bastante distintos, podendo indicar que cada modelo apresenta certa sensibilidade a características específicas presentes no banco de dados.

B. K-Prototypes

Na etapa de aprendizado não supervisionado, a aplicação do algoritmo *K-Prototypes*, com $K = 6$, resultou na identificação de seis perfis de consumo distintos, representando diferentes padrões de demanda nos restaurantes universitários. Os centros dos clusters, que sintetizam o comportamento médio de cada grupo, estão apresentados na Tabela 8.

TABELA 8
CENTROS DOS CLUSTERS ENCONTRADOS PELO ALGORITMO
K-PROTOTYPES

Cluster	Tipo de Refeição	Restaurante Utilizado	Período do Semestre	Dia da Semana	Quantidade (Escalonada)
1	Jantar	RU	meio	qua	0.57
2	Jantar	RA	meio	sex	-0.73
3	Almoço	RS	início	ter	-0.11
4	Almoço	RS	férias	qua	-0.37
5	Almoço	RU	início	seg	1.96
6	Jantar	RS	fim	seg	-0.53

Vale ressaltar quais são os perfis descritivos de cada cluster. O cluster 1 corresponde a uma demanda média-alta (jantar no RU), cluster 2 representa um vale de demanda (jantar no RA), cluster 3 descreve uma demanda média (jantar no RU), cluster 4 caracteriza almoços de demanda baixa (RS), cluster 5 representa um pico de demanda (almoço no RU) e o cluster 6 corresponde a uma demanda baixa (jantar no RS em fim de período). Observações que não foram classificadas pelo algoritmo foram alocadas ao cluster 0.




Gráfico 9. Percentual de restaurantes alocados em cada cluster




Gráfico 10. Distribuição da demanda em cada cluster

A análise dos perfis de consumo relacionados aos clusters e a visualizações dos Gráficos 9 e 10 possibilitam uma abordagem mais clara dos restaurantes e demanda, respectivamente, que permitem as discussões consideradas abaixo:

- Os clusters apresentaram padrões distintos na predominância dos restaurantes. O RU domina os clusters 1 (80%) e 5 (exclusivo), enquanto o RA é majoritário no cluster 2 (70%). Já os clusters 3, 4 e 6 são mistos, porém com predomínio do RS (65%, 65% e 66%, respectivamente), acompanhados por participações menores de RA e RU. Essa distribuição evidencia que o modelo separou os grupos também com base na composição dos restaurantes utilizados.
- O modelo identificou com clareza diferentes níveis de demanda. O pico aparece no cluster 5, com média de 3618 refeições e valor escalonado 1,96, caracterizando dias de almoço no RU em período letivo. No extremo oposto, o cluster 6 apresenta média de 923 refeições e valor escalonado -0,53, associado ao jantar no RS durante as férias. Esses extremos confirmam que o algoritmo distinguiu regimes de demanda fortemente contrastantes.
- As densidades dos clusters mostram formas bem definidas. O cluster 5 apresenta distribuição deslocada para valores altos, com cauda ultrapassando 6000 refeições e grande variabilidade; o cluster 2 concentra-se em valores baixos; os clusters 3, 4 e 6 exibem padrões de demanda de baixa a intermediária; enquanto o cluster 1 apresenta nível médio-alto e forma mais concentrada. Esses resultados reforçam que o modelo identificou grupos com distribuições de demanda estruturalmente diferentes.
- Os padrões entre almoço e jantar permanecem consistentes. Os clusters associados ao jantar (1, 2 e 6) apresentam demandas menores, sendo o cluster 6 (jantar no RS) aquele com o menor valor escalonado (-0,53), enquanto o cluster 1 (jantar no RU) possui valor próximo de 0,57 e média de 2120 refeições. Em contraste, os clusters de almoço concentram as maiores demandas, reforçando a

diferença sistemática entre os horários das refeições.

- O RS aparece como responsável por demandas intermediárias nos clusters 3, 4 e 6, com médias de 1380, 1100 e 923 refeições, variando conforme o momento do semestre e o tipo de refeição. Por outro lado, algumas variáveis apresentaram baixo poder de discriminação, como *categoria_vegano* (predominantemente “leguminosas”, exceto no cluster 5) e *feriado_dummy* (constante em 0), indicando que não contribuíram de forma relevante para a separação dos grupos.

A seguir temos as informações sobre os dias letivos de 20/10/2025 à 27/10/2025, da semana que foi feita a predição.

Na segunda-feira, dia 20/10/2025, ocorreram os clusters 6, 2 e 5. O cluster 6 representou os almoços nos três restaurantes, com demanda média-baixa (média ≈ 1145); o cluster 2 correspondeu ao jantar no RU, associado a demanda baixa-intermediária (média ≈ 1408); e o cluster 5 reuniu os jantares no RA e RS, caracterizados por baixa demanda (média ≈ 973).

Na terça-feira, dia 21/10/2025, foram observados os clusters 6 e 3. O cluster 6 incluiu almoços no RU e RS e jantares no RU, RA e RS, mantendo o perfil de demanda média-baixa; enquanto o cluster 3, presente no almoço do RA, apresentou demanda moderada (média ≈ 1646).

Na quarta-feira, dia 22/10/2025, surgiram os clusters 6, 3 e 5. O cluster 6 apareceu nos almoços do RU e RS, novamente com demanda média-baixa; o cluster 3 reuniu o almoço e o jantar no RA, com demanda moderada; e o cluster 5 marcou os jantares no RU e RS, com baixa demanda.

Na quinta-feira, dia 23/10/2025, os clusters identificados foram 6 e 3. O cluster 6 concentrou almoços e jantares no RU e RS, mantendo o perfil de demanda média-baixa; e o cluster 3 abrangeu almoço e jantar no RA, associado a demanda moderada.

Já na sexta-feira, dia 24/10/2025, apareceram os clusters 6, 3 e 2. O cluster 6 correspondeu aos almoços no RU e RS e aos jantares no RA e RS, novamente com demanda média-baixa; o cluster 3 representou o almoço no RA, com demanda moderada; e o cluster 2 surgiu no jantar do RU, marcado por demanda baixa-intermediária.

As Tabelas 9 e 10 apresentam os resultados condensados da clusterização:

TABELA 9
RESUMO DESCRITIVO POR CLUSTER

Cluster	Observações	Quantidade Média	Desvio-Padrão
1	267	2120	724
2	470	713	342
3	376	1380	430
4	336	1100	532
5	291	3618	643
6	387	923	515

A coluna “Total Previsto” da Tabela 10 diz referência aos valores previstos pelos clusters, ou seja, como os dados estão separados em almoço e jantar e entre os restaurantes, foi considerado em qual cluster cada uma dessas observações

estava e em seguida, foi somada a quantidade média dos clusters, explicitada na tabela 9, para enfim, chegar ao resultado apresentado, que se encontra consistente pois os valores estão no respectivo intervalo de confiança.

TABELA 10
TOTAL PREVISTO POR DIA, DESVIO PADRÃO E INTERVALOS DE CONFIANÇA (IC 95%)

Dia da semana	Total Previsto	Desvio Padrão	IC 95%
Segunda	10719	1319.396	(8132.51, 13304.54)
Terça	5995	1229.818	(3584.08, 8404.97)
Quarta	11842	1314.723	(9264.69, 14418.41)
Quinta	6451	1196.718	(4105.46, 8796.59)
Sexta	5785	1167.958	(3495.31, 8073.70)

VI. CONCLUSÃO

O presente artigo teve como propósito principal avaliar o desempenho de dois algoritmos de aprendizado de máquina supervisionado na previsão da demanda diária de refeições servidas nos restaurantes universitários da Unicamp: Árvore de Decisão e Regressão Binomial Negativa. A comparação entre ambos permitiu identificar suas potencialidades e limitações frente ao problema proposto, considerando tanto aspectos de acurácia quanto de interpretabilidade dos modelos.

Além disso, aplicou-se um método de aprendizado de máquina não supervisionado a fim de encontrar clusters presentes no banco de dados para buscar identificar padrões representativos de consumo nos restaurantes universitários. O algoritmo aplicado para tal função foi o *K-Prototypes*, que se mostrou eficaz na clusterização de dados mistos, combinando as variáveis numéricas e categóricas presentes no banco de dados. Os seis perfis obtidos oferecem *insights* operacionais valiosos, destacando contrastes nítidos entre picos de consumo (almoço no RU no meio do semestre) e vales de demanda (jantar em períodos de férias).

De maneira geral, os resultados indicam que os dois modelos do aprendizado supervisionado apresentaram desempenho satisfatório, sendo capazes de capturar o comportamento padrão do consumo de refeições ao longo da semana. O modelo de Árvore de Decisão demonstrou maior capacidade explicativa, com coeficiente de determinação elevado e boa adequação às variações observadas nos dados. Já a Regressão Binomial Negativa apresentou menor erro médio absoluto em comparação à árvore, mostrando-se mais robusta na predição de contagens e confirmando sua adequação a dados com sobredispersão.

Somado a isso, após a clusterização, pode-se verificar na Tabela 11 que, para ambos os modelos de predição via aprendizado supervisionado, a menos da terça-feira na Árvore de Decisão e da quarta-feira em ambos os modelos, os resultados obtidos se encontram dentro dos intervalos de confiança prescritos.

TABELA 11
COMPARAÇÃO DOS RESULTADOS DE PREVISÃO ENTRE OS MODELOS

Dia da Semana	Árvore de Decisão	Binomial Negativa	IC (Clusters)
Segunda	10811	8237	(8132.51, 13304.54)
Terça	9464	8322	(3584.08, 8404.97)
Quarta	7392	5963	(9264.69, 14418.41)
Quinta	7610	7612	(4105.46, 8796.59)
Sexta	7153	6657	(3495.31, 8073.70)

Assim, conclui-se que as predições realizadas pelos modelos de aprendizado supervisionado apresentam certo alinhamento com o comportamento típico dos dados referentes a esses dias da semana.

Essas análises contribuem diretamente para o objetivo do estudo, ao oferecer uma ferramenta preditiva e indicativa de perfis de consumo que pode subsidiar o planejamento operacional dos restaurantes universitários, reduzindo o desperdício de alimentos e promovendo o uso mais racional dos recursos disponíveis.

VII. AGRADECIMENTOS

Os autores agradecem à Prefeitura Universitária da Unicamp e ao Serviço de Informações ao Cidadão (SIC-Unicamp) pelo fornecimento dos dados. À Google DeepMind pelo suporte financeiro.

VIII. USO DE IA

Durante o desenvolvimento do artigo, os autores utilizaram o ChatGPT [https://chatgpt.com/] versão 3.5 para pequenos ajustes nos códigos dos modelos utilizados. Após o uso da mesma, as respostas obtidas dos questionamentos passaram por revisão minuciosa e os conteúdos foram editados para estarem em conformidade com o método científico. Os autores assumem total responsabilidade pelo conteúdo presente neste trabalho.

REFERÊNCIAS

- [1] G. S. da Conceição, C. R. do Nascimento de Lira, and M. da Conceição Pereira da Fonseca, "Desperdício de alimentos em restaurante universitário: avaliação por resto-ingestão e pesquisa de satisfação," *Revista Simbio-Logias*, vol. 13, no. 18, 2021.
- [2] C. Brasil. (2024, nov) Brasil descarta 30% dos alimentos produzidos, diz onu. Acessado em: 19 set. 2025. [Online]. Available: <https://www.cnnbrasil.com.br/nacional/brasil-descarta-30-dos-alimentos-produzidos-diz-onu/>
- [3] E. eCycle, "Desperdício de alimentos: causas e prejuízos," eCycle, 2023, disponível em: <https://www.ecycle.com.br/desperdicio-de-alimentos/>. Acesso em: 19 set. 2025.
- [4] J. A. Santos. (2015, dec) Desperdício de alimentos em restaurantes universitários no brasil. Acessado em: 19 set. 2025. [Online]. Available: <https://repositorio.ufrn.br/handle/123456789/40157>
- [5] D. C. Montgomery, *Design and Analysis of Experiments*, 10th ed., ser. Wiley Series in Probability and Statistics. Wiley, 2022.
- [6] M. C. Monard and J. A. Baranauskas, "Indução de regras e Árvores de decisão," in *Sistemas Inteligentes para Engenharia*. Universidade de São Paulo, 2003, ch. 5, acessado em: 19 set. 2025. [Online]. Available: <https://dcm.ffclrp.usp.br/~augusto/publications/2003-sistemas-inteligentes-cap5.pdf>
- [7] G. Candido. (2023, Oct) Árvore de decisão: Um dos algoritmos mais poderosos do aprendizado de máquina. Online article. Data Hackers. Acessado em: 18 set. 2025. [Online]. Available: <https://medium.com/data-hackers/%C3%A1rvore-de-decis%C3%A3o-88c7d0fd7a31>

- [8] A. Hermuche. (2020) Tutorial de clusterização de dados categóricos e mistos com k-prototypes. Online article. Medium. Acesso em: 18 nov. 2025. [Online]. Available: <https://medium.com/@anwarhermuche/tutorial-de-clusteriza%C3%A7%C3%A3o-de-dados-categ%C3%B3ricos-e-mistos-com-k-prototypes-98a2115a6b9f>
- [9] J. Metz, "Interpretação de clusters gerados por algoritmos de clustering hierárquico," Master's thesis, Instituto de Ciências Matemáticas e de Computação (ICMC), Universidade de São Paulo, São Carlos, Brasil, jun 2006, disponível em: https://www.teses.usp.br/teses/disponiveis/55/55134/tde-14092006-090701/publico/master_jean_metz.pdf.
- [10] R Core Team, *R: A Language and Environment for Statistical Computing*, R Foundation for Statistical Computing, Vienna, Austria, 2025. [Online]. Available: <https://www.R-project.org/>
- [11] Google, "Google Colaboratory," <https://colab.research.google.com/>, acesso em: 18 nov. 2025.