

Entrega I - Banco de Dados

Amanda Montezano de Almeida
Estatística
Universidade Estadual de Campinas
204207

Ana Beatriz Rodrigues Carvalho
Matemática Aplicada e Computacional
Universidade Estadual de Campinas
238029

Daniela Cielo Cuadrao Pérez
Estatística
Universidade Estadual de Campinas
298825

Guilherme Duarte Alves Basso
Estatística
Universidade Estadual de Campinas
240805

Luiza Bernardi da Silva
Estatística
Universidade Estadual de Campinas
236218

Marcus Vinícius Pimenta Soares
Matemática Aplicada e Computacional
Universidade Estadual de Campinas
297346

Sofia Moreira Marinho
Estatística
Universidade Estadual de Campinas
236305

Abstract—Este trabalho, desenvolvido no âmbito da disciplina **Aprendizado de Máquina – Aspectos Teóricos e Práticos**, tem como finalidade a criação de um banco de dados detalhado, que servirá de base para dois projetos subsequentes ao longo do semestre. O estudo proposto pelo grupo busca avaliar se o consumo de refeições nos restaurantes universitários da Unicamp é influenciado pela fase do semestre (início, meio e fim). O conjunto de dados que fundamenta a análise foi obtido junto à Prefeitura da Unicamp, garantindo consistência e confiabilidade às informações utilizadas. A análise preliminar indica que, no início do semestre, a quantidade de refeições servidas (almoço e jantar) é expressivamente maior em comparação ao fim do semestre, resultando em uma diferença acumulada de aproximadamente 125 mil refeições ao somar todas as unidades.

Palavras-chave—Dados, Consumo, Refeição

I. INTRODUÇÃO

Um dos principais desafios enfrentados pelos restaurantes universitários é o controle da quantidade de alimentos produzidos e armazenados, tarefa que exige fiscalização rigorosa para evitar desperdícios e garantir a qualidade das refeições servidas. De acordo com a Food and Agriculture Organization of the United Nations (FAO, 2013), cerca de 1,3 bilhão de toneladas de alimentos são descartados anualmente no mundo. Desse total, aproximadamente 350 milhões de toneladas correspondem ao desperdício na etapa de consumo, sendo que o setor de alimentação coletiva é responsável por 15% a 20% [1]. No Brasil, a situação é igualmente alarmante: segundo a ONU, são desperdiçadas 46 milhões de toneladas de alimentos por ano [2], [3].

Esse panorama reflete-se também nos restaurantes universitários, onde o desperdício pode estar associado a diferentes fatores, tais como falta de conscientização dos consumidores, problemas de gestão interna das empresas responsáveis pelo preparo das refeições, deficiências na divulgação dos cardápios ou ainda falhas na previsão de demanda, influenciada por condições externas. Diversas abordagens podem ser empregadas para mitigar tais problemas, incluindo políticas de

conscientização e educação alimentar, melhoria nos processos logísticos e de gestão, além de soluções computacionais baseadas em análise de dados e aprendizado de máquina, capazes de auxiliar na previsão da demanda e no planejamento de produção.

Nesse contexto, este trabalho tem como foco a criação de um banco de dados estruturado com informações relevantes sobre o consumo nos restaurantes universitários da Universidade Estadual de Campinas (Unicamp), abrangendo três unidades analisadas. Observa-se, em especial, que a fase do semestre (início, meio e fim) exerce influência significativa sobre o volume de refeições servidas, aspecto que torna ainda mais urgente o desenvolvimento de modelos preditivos capazes de considerar variações temporais. O gráfico abaixo evidencia esse comportamento, analisado pelo grupo antes do início do tratamento dos dados.




Gráfico 1. Comportamento do Consumo no Período de Fevereiro 2024 a Julho de 2025.

O período de férias, embora registrado no banco de dados, não foi considerado para fins de análise, uma vez que não

reflete o comportamento regular de consumo. Sendo assim, a divisão em início, meio e fim é dada por

$$I, M, F = \frac{D_l}{3},$$

Onde:

I = Início, M = Meio, F = Fim,

D_l = Dias letivos do semestre analisado.

Para a definição das fases analisadas, adotou-se a seguinte convenção: o *início* corresponde ao primeiro dia de aula do período letivo, conforme estabelecido no calendário acadêmico da Unicamp; o *fim* é definido como o último dia do período letivo, também de acordo com o referido calendário; e o *meio* representa a etapa intermediária, obtida pela divisão do total de dias letivos em três partes.

Quando a divisão não resulta em um número inteiro, o maior valor é atribuído à fase final, já que esta concentra, de forma notável, a menor quantidade de consumo. Tal como mostra na tabela 1.

TABELA 1
DIAS ATRIBUÍDOS A CADA CLASSIFICAÇÃO

Semestre	Início (Dias)	Meio (Dias)	Fim (Dias)	Total (Dias)
1s2024	43	43	43	129
2s2024	42	42	44	128
1s2025	46	46	46	138

Assim, o banco de dados construído servirá como base primária para a aplicação de técnicas de aprendizado de máquina, com o objetivo de apoiar a gestão no manejo e na previsão de consumo, contribuindo para a redução do desperdício e para uma gestão alimentar mais eficiente.

II. METODOLOGIA

A coleta de dados foi realizada junto à Prefeitura Universitária da Unicamp, que disponibilizou duas planilhas em formato Excel: a primeira contendo os cardápios diários e a segunda com o registro do volume de pessoas que acessaram os restaurantes universitários da instituição — RU (Restaurante Universitário), RA (Restaurante Administrativo) e RS (Restaurante Saturnino).

Os cardápios disponibilizados abrangiam o período a partir de 2022; entretanto, os dados de volumetria estavam disponíveis apenas a partir de 2024. Dessa forma, para possibilitar o cruzamento das informações, foi necessário restringir a análise ao intervalo em que ambos os conjuntos de dados estavam presentes. Assim, foram considerados os registros compreendidos entre o início do período letivo, em 28/02/2024, e o término do primeiro semestre letivo de 2025, em 12/07/2025.

Nesse recorte temporal, estão disponíveis de forma consistente tanto os cardápios quanto os volumes de acesso referentes a cada dia e a cada restaurante.

Ao realizar a análise inicial e a etapa de limpeza do banco de dados, foram identificadas as seguintes variáveis: data, refeição, acompanhamento, prato, guarnição, opção vegetal,

salada, sobremesa e suco. Dentre essas, efetuiu-se uma filtragem, de modo a considerar apenas três variáveis: a data da refeição, o tipo de refeição e o prato correspondente.

Essa escolha deve-se ao fato de que, para os objetivos desta análise, o foco recaiu sobre a identificação do tipo de refeição (almoço padrão, almoço vegano, jantar padrão ou jantar vegano) em cada data, bem como do prato principal servido — isto é, a fonte proteica de maior relevância no cardápio. As demais variáveis, como acompanhamentos, guarnições ou sobremesas, não foram incluídas por não desempenharem papel significativo no escopo do estudo.

Durante esse processo, foram identificados alguns problemas relacionados à ausência de informações em determinados dias. Além disso, constatou-se que, no período compreendido entre o início de 2024 e abril do mesmo ano, os restaurantes universitários da Unicamp não funcionavam aos finais de semana e feriados. Cabe destacar, ainda, que aos domingos e feriados é servido exclusivamente o almoço.

A. Variáveis do Banco

O banco de dados de cardápios continha os diferentes tipos de refeição oferecidos pelos restaurantes universitários. Para fins de análise, os cardápios foram inicialmente divididos em duas categorias: padrão e vegano.

No tratamento dos dados referentes ao cardápio padrão, empregaram-se palavras-chave associadas ao tipo de proteína principal oferecida em cada prato. Por exemplo, no prato "filé de pescada ao molho", a ocorrência da palavra "pescada" possibilitou a classificação do prato na categoria "peixe".

Além disso, foi contabilizada a frequência de ocorrência de cada proteína, como indicado na tabela apresentada. Cabe destacar que a feijoada e o ovo, por se tratarem de preparações específicas que não se enquadram em nenhuma das demais categorias proteicas, foram agrupados em categorias próprias.

TABELA 2
DESCRIÇÃO DAS CATEGORIAS DE PROTEÍNA PADRÃO E SUAS QUANTIDADES

Categoria Padrão	Informação	Quantidade
Bovino	"boi", "bovino", "bife", "carne", "lagarto", "iscas bovinas", "ácem", "patinho", "almôndega"	1061
Frango	"frango", "sobrecoxa", "nugget"	747
Suíno	"suíno", "bisteca", "suína", "pernil", "linguiça toscana", "copa lombo"	347
Peixe	"peixe", "tilápia", "pescada"	274
Feijoada	"feijoada"	48
Ovo	"fritada", "omelete"	15
Bovino e Suíno	"bovinos e suínos", "salsicha"	13
Outros		5

De maneira análoga ao cardápio padrão, a tabela abaixo apresenta a organização das refeições do cardápio vegano no banco de dados, assim como a frequência com que cada uma delas foi oferecida.

TABELA 3
DESCRIÇÃO DAS CATEGORIAS DE PROTEÍNA VEGANA E SUAS QUANTIDADES

Categoria Vegana	Informação	Quantidade
Leguminosas	"feijão", "lentilha", "grão-de-bico", "ervilha", "soja", "grão de bico", "feijão branco", "fradinho", "mix de feijões", "leilha"	1740
Proteína Texturizada	"pts", "proteína texturizada", "almôndega vegana", "stroganoff vegano", "quibe de pts", "fricassê de pts", "fricassê vegano"	709
Vegetais	"quibe de abóbora", "quibe de brócolis"	29
Cereais Integrais	"arroz integral", "quinoa", "aveia", "trigo", "cevada", "milho", "arroz 7 grãos", "cuscuz", "cuzcuz"	15
Feijoada Vegana	"feijoada vegana"	12
Outros		7

Assim que as variáveis foram definidas, procedeu-se à transformação e atribuição de suas respectivas funções. Na Tabela 4 estão discriminados os tipos de variáveis presentes no banco de dados, onde "fct" significa que é um fator e representa variáveis categóricas e "dbl" significa que a variável quantidade foi armazenada como números reais.

TABELA 4
VARIÁVEIS DO BANCO E SEUS TIPOS

Variáveis do Banco	Tipo	Organização
Data	date	2024-02-28, 2024-02-28, ...
Tipo Refeição	fct	Almoço, Jantar, ...
Restaurante Utilizado	fct	RU, RA, RS, ...
Categoria Padrão	fct	bovino, bovino, bovino, ...
Categoria Vegano	fct	leguminosas, leguminosas, ...
Dia da Semana	fct	qua, qua, qua, ...
Mês	fct	fev, fev, fev, ...
Almoço	fct	1, 1, 1, 0, 0, ...
Período Semestre	fct	inicio, inicio, inicio, ...
Quantidade	dbl	4112, 1155, 1384, ...

Durante o processo de limpeza para a construção da estrutura final, algumas particularidades foram observadas. Em determinados dias, a proteína principal indicada no cardápio variava entre restaurantes — por exemplo, constava como "frango" no RA/RS, mas como "linguiça" no RU. Esses casos exigiram tratamento manual, sendo necessário padronizar os nomes dos pratos para identificar corretamente o restaurante associado. Quando não havia indicação explícita do restaurante, o prato foi mantido sem alteração.

Além disso, inconsistências pontuais foram corrigidas com base em um arquivo externo de referência. Foram criadas colunas binárias para indicar a disponibilidade do prato em cada restaurante (RU, RA, RS ou *outro* — categoria utilizada em situações específicas como CAISM e HC). Posteriormente, essas colunas foram unificadas em uma única variável que identifica o restaurante, e adicionaram-se contagens de registros por data.

Durante o processo de limpeza do banco de dados, foram identificados valores registrados como N/A, os quais cor-

respondem a dados faltantes. A análise indicou que tais ocorrências estão associadas, em sua maioria, aos domingos sem oferta de refeições (particularmente no jantar) e a feriados.

Adicionalmente, foram observados quatro registros com quantidade igual a zero no banco de dados original, correspondentes às seguintes datas: 28/01/2025, 26/04/2025, 05/07/2025 e 12/07/2025. Nesses casos, nenhuma ação de imputação ou manipulação é possível, uma vez que os restaurantes não abriram, caracterizando dados de fato inexistentes.

Ao filtrar o banco exclusivamente para os casos em que a quantidade apresenta valor N/A, foram encontrados 380 registros, distribuídos em 99 dias distintos com ausência de informação.

Por fim, os bancos referentes aos pratos veganos, padrão e inconsistentes foram integrados, originando um banco de dados único e devidamente limpo.

B. Testes Estatísticos

Considerando o gráfico de calor abaixo, observa-se que, independente do período, o almoço é a refeição que apresenta a maior demanda. Observa-se também que, ao decorrer do semestre existe uma queda do número de refeições servidas, o que motiva o escopo deste trabalho, visto que é necessário que haja quantidade suficiente de comida no início e que não se desperdice alimento no fim.




Gráfico 2. Mapa de calor da média de refeições por período do semestre

Com isso, iniciou-se uma análise mais descritiva dos dados, onde notou-se também uma diferença entre a quantidade de refeições servidas por cada restaurante. Sendo assim, foi ajustado um modelo estatístico de Planejamento por Blocos Completos a fim de verificar como essa diferença se comportava. Como o interesse do trabalho é no efeito do início, meio e fim do semestre letivo, os restaurantes foram utilizados como variável de controle. Assim, foi considerado o modelo:

$$Y_{ij} = \mu + \alpha_i + \tau_j + \xi_{ij}, \quad \xi_{ij} \sim \text{i.i.d. } N(0, \sigma^2)$$

onde:

- Y_{ij} : número de refeições servidas no restaurante j durante o período i ;

- α_i : efeito fixo do período do semestre (i = início, meio, fim, férias);
- τ_j : efeito fixo do restaurante (j = RA, RS, RU);
- ξ_{ij} : erro aleatório independente e normalmente distribuído.

As restrições adotadas foram $\alpha_1 = \tau_1 = 0$, neste caso o período das férias e o restaurante RA .

Com isso, foi possível organizar a tabela abaixo:

TABELA 5
ESTATÍSTICAS DESCRITIVAS POR PERÍODO DO SEMESTRE

Período\Semestre	Mínimo	Máximo	Variância	Média
Início	157	4891	1384856.1	1814.70
Meio	0	5026	1159543.8	1656.09
Fim	0	6730	1017810.6	1468.50
Férias	0	2271	280867.6	769.90

Observando a tabela, é notável as diferenças entre os períodos avaliados, onde as médias apresentam uma variação entre 769,90 e 1814,70 de refeições servidas. Para complementar, foi analisada a variabilidade entre as médias dos períodos (aproximadamente 212.097,4) e a média das variâncias dentro de cada período (aproximadamente 960.769,5). Idealmente, espera-se que a variabilidade entre os períodos seja pequena (próxima de zero) caso o período do semestre não tenha efeito, o que não é o caso observado.

Nota-se que a variabilidade entre os períodos é significativamente inferior à variabilidade intra-período, mas ainda suficiente para indicar, de forma descritiva, que existem diferenças relevantes no consumo de refeições ao longo do semestre letivo.

Também foi realizada uma análise de variância (ANOVA) do modelo. Utilizando os fatores do período do semestre e do restaurante utilizado, verificou-se que ambos apresentam efeito significativo sobre a quantidade de refeições servidas, com o teste F e o valor-p sendo $F = 229,85$; $p < 2.2 * 10^{-16}$ e $F = 1860,84$; $p < 2.2 * 10^{-16}$, respectivamente.

Comparação	Estatística F	p-valor
Meio vs Início	268.08	$< 1e-16$
Fim vs Início	588.31	$< 1e-16$
Férias vs Início	433.27	$< 1e-16$
Meio vs Fim	83.27	$< 1e-16$
Meio vs Férias	26.37	$3.082e-07$
Fim vs Férias	15.92	$6.819e-05$

A tabela acima é uma comparação múltipla entre os períodos do semestre, onde todas as comparações apresentam diferenças estatisticamente significativas. Ressalta-se que, como foram realizados vários testes de hipóteses, foi utilizado o ajuste de Bonferroni. Ainda vale destacar que o contraste entre início e fim do período é o mais expressivo, indicando um consumo significativamente maior no início do semestre.

III. DISCUSSÕES

Todos os problemas encontrados na criação do banco de dados não impactam diretamente na análise da fase do semestre, que se mostra expressamente maior no início em comparação ao fim. As análises estatísticas fundamentam essa observação. Não é escopo deste estudo explicar em detalhes as razões pelas quais esse comportamento ocorre, questões como calendário acadêmico, comportamento dos estudantes e eventos externos podem influenciar esses resultados, mas sim evidenciar sua existência e, futuramente, possibilitar a construção de algoritmos preditivos capazes de estimar essa demanda com base no banco de dados desenvolvido.

É importante ressaltar que as inconsistências encontradas durante o processo de limpeza — como valores ausentes (N/A) em dias específicos — não comprometem a integridade do conjunto, uma vez que tais ausências correspondem a situações em que o restaurante não abriu, como domingos ou feriados. Dessa forma, esses dados são inexistentes e não há manipulação estatística que possa ser aplicada de forma coerente.

Como pode ser observado no gráfico abaixo, a criação do banco de dados possibilitou identificar padrões distintos de consumo de refeições ao longo do semestre. No início, as quartas e quintas-feiras apresentam maior concentração de consumo; no período intermediário, essa predominância se desloca para segundas e terças-feiras; e, ao final do semestre, observa-se maior demanda às terças-feiras. Já durante o período de férias, o maior número de refeições ocorre, de forma consistente, às segundas e terças-feiras.




Gráfico 3. Quantidade de Refeições Servidas por Período e Dia da semana

O gráfico abaixo mostra o comportamento do consumo médio de refeições (almoço + jantar) nos períodos em cada restaurante. Observa-se claramente que o Restaurante Universitário (RU) apresenta o maior número de refeições servidas, o que pode ser explicado pelo seu maior tamanho e pela localização mais central, próxima a diversos institutos da universidade, tornando-o mais acessível para grande parte dos estudantes e funcionários.




Gráfico 4. Média do consumo de refeições por restaurante e período do semestre

Por fim, a principal contribuição desta análise reside em demonstrar a viabilidade do banco de dados como instrumento para estudos futuros, especialmente no desenvolvimento de modelos de previsão de demanda. Ao evidenciar a estrutura e os padrões identificados, abre-se espaço para aplicações práticas que possam auxiliar na gestão eficiente de recursos, reduzindo desperdícios e otimizando o planejamento operacional do restaurante universitário.

IV. CONCLUSÃO E PRÓXIMOS PASSOS

Este trabalho apresentou a construção e análise preliminar de um banco de dados robusto e detalhado sobre o consumo de refeições nos restaurantes universitários da Unicamp, abrangendo o período de fevereiro de 2024 a julho de 2025. Os resultados obtidos confirmam a hipótese inicial de que o consumo de refeições varia significativamente ao longo do semestre, sendo maior no início e reduzindo-se progressivamente até o fim.

Além disso, a análise estatística realizada — por meio de modelo de blocos completos e ANOVA — evidenciou que tanto o período do semestre quanto o restaurante utilizado exercem influência significativa na quantidade de refeições servidas. A consistência desses resultados valida a qualidade do banco de dados construído e sua adequação para aplicações em modelos preditivos.

Com base no banco de dados construído, a próxima etapa deste trabalho consistirá na aplicação de técnicas de aprendizado supervisionado para prever o número de usuários por dia em cada restaurante universitário. Serão explorados modelos com diferentes graus de interpretabilidade, a fim de equilibrar acurácia e transparência na previsão de demanda.

REFERÊNCIAS

- [1] G. S. da Conceição, C. R. do Nascimento de Lira, and M. da Conceição Pereira da Fonseca, "Desperdício de alimentos em restaurante universitário: avaliação por resto-ingestão e pesquisa de satisfação," *Revista Simbio-Logias*, vol. 13, no. 18, 2021.

- [2] C. Brasil. (2024, nov) Brasil descarta 30% dos alimentos produzidos, diz onu. Acessado em: 19 set. 2025. [Online]. Available: <https://www.cnnbrasil.com.br/nacional/brasil-descarta-30-dos-alimentos-produzidos-diz-onu/>
- [3] E. eCycle, "Desperdício de alimentos: causas e prejuízos," eCycle, 2023, disponível em: <https://www.ecycle.com.br/desperdicio-de-alimentos/>. Acesso em: 19 set. 2025.
- [4] D. C. Montgomery, *Design and Analysis of Experiments*, 10th ed., ser. Wiley Series in Probability and Statistics. Wiley, 2022.