

Entrega II - Previsão da quantidade de refeições servidas nos Restaurantes Universitários da Unicamp utilizando Aprendizado de Máquina Supervisionado

Amanda Montezano de Almeida
Estatística
Universidade Estadual de Campinas
204207

Ana Beatriz Rodrigues Carvalho
Matemática Aplicada e Computacional
Universidade Estadual de Campinas
238029

Daniela Cielo Cuadrao Pérez
Estatística
Universidade Estadual de Campinas
298825

Guilherme Duarte Alves Basso
Estatística
Universidade Estadual de Campinas
240805

Luiza Bernardi da Silva
Estatística
Universidade Estadual de Campinas
236218

Marcus Vinícius Pimenta Soares
Matemática Aplicada e Computacional
Universidade Estadual de Campinas
297346

Sofia Moreira Marinho
Estatística
Universidade Estadual de Campinas
236305

Abstract—Este trabalho, desenvolvido no âmbito da disciplina **Aprendizado de Máquina – Aspectos Teóricos e Práticos**, tem como finalidade a **predição da demanda diária de refeições servidas nos Restaurantes Universitários da Universidade Estadual de Campinas (Unicamp)** utilizando dois algoritmos de aprendizado supervisionado, árvores de decisão e regressão binomial negativa.

Palavras-chave—Aprendizado de máquina supervisionado, regressão binomial negativa, árvore de decisão.

I. INTRODUÇÃO

O presente trabalho constitui a segunda etapa do projeto desenvolvido na disciplina **Aprendizado de Máquina – Aspectos Teóricos e Práticos**, e dá continuidade à pesquisa iniciada com a construção de um banco de dados detalhado sobre o consumo de refeições nos restaurantes universitários da Universidade Estadual de Campinas (Unicamp). Na etapa anterior, buscou-se compreender a variação no número de refeições servidas ao longo do semestre letivo, identificando diferenças significativas entre os períodos de início, meio e fim. As análises estatísticas realizadas demonstraram que o consumo tende a ser mais elevado no início do semestre e decresce progressivamente até o final, evidenciando um comportamento sazonal que impacta diretamente o planejamento e a gestão alimentar das unidades.

A partir dessas constatações, esta segunda fase tem como objetivo aplicar técnicas de aprendizado de máquina supervisionado para a previsão da demanda diária de refeições nos restaurantes universitários. Serão implementados dois algoritmos supervisionados com o intuito de avaliar sua capacidade preditiva e a adequação de seus resultados ao prob-

lema estudado. A construção e o treinamento dos modelos baseiam-se no banco de dados previamente desenvolvido, o qual contém informações referentes aos cardápios, tipos de refeição, categorias proteicas, períodos do semestre e unidades de atendimento.

O propósito central deste estudo é contribuir para a redução do desperdício de alimentos, um problema de grandes proporções em escala global e que também se manifesta nos restaurantes universitários. A utilização de modelos preditivos baseados em aprendizado de máquina possibilita estimar com maior precisão a demanda diária por refeições, favorecendo o planejamento de produção e o uso racional de recursos. Dessa forma, a aplicação de técnicas de aprendizado supervisionado neste contexto busca não apenas aprimorar a acurácia das previsões, mas também estimular práticas sustentáveis que promovam a eficiência operacional e a diminuição de perdas alimentares no ambiente universitário.

II. METODOLOGIA

A base de dados utilizada neste trabalho foi construída a partir de informações disponibilizadas pela Prefeitura Universitária da Unicamp, que forneceu duas planilhas em formato Excel: uma contendo os cardápios diários e outra com o registro do número de usuários que acessaram os restaurantes universitários da instituição — RU (Restaurante Universitário), RA (Restaurante Administrativo) e RS (Restaurante Saturnino).

Para possibilitar o cruzamento das informações, foram considerados os registros compreendidos entre o início do período

letivo, em 28/02/2024, e o término do primeiro semestre de 2025, em 12/07/2025. Esse recorte garante a disponibilidade consistente de dados tanto sobre os cardápios quanto sobre o volume de refeições servidas.

Durante a etapa de limpeza e estruturação, identificaram-se e corrigiram-se inconsistências relacionadas a valores ausentes, padronização de nomes de pratos e diferenças entre restaurantes em um mesmo dia. Foram removidos os registros referentes a finais de semana e feriados, períodos em que o funcionamento não é regular. Após o tratamento, os bancos referentes aos cardápios padrão e vegano foram integrados, originando uma única base de dados consolidada e pronta para a aplicação dos modelos de aprendizado supervisionado.

A. Variáveis do banco

A Tabela 1 apresenta as categorias de proteína utilizadas nos cardápios padrão e suas respectivas frequências. Essas categorias foram definidas a partir da ocorrência de palavras-chave no nome do prato principal, permitindo a classificação automática do tipo de proteína oferecida.

TABELA 1
DESCRIÇÃO DAS CATEGORIAS DE PROTEÍNA PADRÃO E SUAS QUANTIDADES

Categoria Padrão	Informação	Quantidade
Bovino	"boi", "bovino", "bife", "carne", "lagarto", "iscas bovinas", "ácem", "patinho", "almôndega"	1061
Frango	"frango", "sobrecoca", "nugget"	747
Suíno	"suíno", "bisteca", "suína", "pernil", "linguiça toscana", "copa lombo"	347
Peixe	"peixe", "tilápia", "pescada"	274
Feijoad	"feijoad"	48
Ovo	"fritada", "omelete"	15
Bovino e Suíno	"bovinos e suínos", "salsicha"	13
Outros		5

De maneira análoga, a Tabela 2 apresenta as categorias de proteína do cardápio vegano e a frequência com que cada uma foi oferecida no período analisado.

TABELA 2
DESCRIÇÃO DAS CATEGORIAS DE PROTEÍNA VEGANA E SUAS QUANTIDADES

Categoria Vegana	Informação	Quantidade
Leguminosas	"feijão", "lentilha", "grão-de-bico", "ervilha", "soja", "feijão branco", "fradinho", "mix de feijões"	1740
Proteína Texturizada	"pts", "proteína texturizada", "almôndega vegana", "stroganoff vegano", "quibe de pts", "fricassê vegano"	709
Vegetais	"quibe de abóbora", "quibe de brócolis"	29
Cereais Integrais	"arroz integral", "quinoa", "aveia", "trigo", "milho", "arroz 7 grãos", "cuscuz"	15
Feijoad Vegana	"feijoad vegana"	12
Outros		7

As variáveis presentes no banco final estão apresentadas na Tabela 3. As variáveis categóricas foram transformadas em

fatores (fct) e as quantitativas armazenadas como números reais (dbl), conforme padrão adotado para o pré-processamento dos modelos.

TABELA 3
VARIÁVEIS DO BANCO E SEUS TIPOS

Variável	Tipo	Descrição
Data	date	Data da observação
Tipo Refeição	fct	Almoço ou jantar
Restaurante Utilizado	fct	RU, RA ou RS
Categoria Padrão	fct	Tipo de proteína principal (bovino, frango, etc.)
Categoria Vegano	fct	Tipo de proteína principal (leguminosas, PTS, etc.)
Dia da Semana	fct	Segunda a sexta-feira
Mês	fct	Mês correspondente à data
Almoço	fct	Indicador binário para refeição
Período Semestre	fct	Início, meio ou fim do semestre
Quantidade	dbl	Número de refeições servidas

Após essas etapas, obteve-se um banco consolidado, livre de inconsistências e com as variáveis devidamente estruturadas para a modelagem. Essa base serviu como ponto de partida para a aplicação dos algoritmos de aprendizado supervisionado, detalhados nas subseções seguintes.

Nesta etapa do projeto, foram aplicadas técnicas de aprendizado supervisionado com o objetivo de prever a quantidade de refeições servidas nos restaurantes universitários da Universidade Estadual de Campinas (Unicamp). Foram implementados dois modelos distintos: Árvore de Decisão e Regressão Binomial Negativa. A comparação entre esses métodos permite avaliar o desempenho de algoritmos de naturezas diferentes, considerando critérios de precisão e interpretabilidade.

B. Preparação dos dados

A base utilizada corresponde ao conjunto construído na primeira etapa do projeto, contendo informações sobre cardápios, tipos de refeição, categorias proteicas, restaurantes, dias da semana, meses, períodos do semestre e feriados. Inicialmente, foram removidos os valores ausentes (NA) e excluídos os registros referentes a sábados e domingos, pois o objetivo da previsão se restringe aos dias úteis.

As variáveis consideradas como preditoras foram: *tipo_refeicao*, *restaurante_utilizado*, *categoria_padrao*, *categoria_vegano*, *dia_semana*, *mes*, *almoco*, *periodo_semestre* e *feriado_dummy*. A variável-alvo é a *quantidade*, correspondente ao número de refeições servidas por dia.

Para a utilização dos modelos, as variáveis categóricas foram transformadas em variáveis do tipo dummy, gerando colunas binárias correspondentes a cada categoria. Após o processamento, o conjunto final apresentou 1.920 observações.

C. Árvore de Decisão

1) *Aspectos teóricos*: O modelo de Árvore de Decisão é uma técnica de aprendizado supervisionado que realiza divisões sucessivas no conjunto de dados, criando partições cada vez mais homogêneas em relação à variável de interesse. Cada nó representa uma condição sobre uma variável preditora e cada folha corresponde ao valor previsto.

O algoritmo busca particionar o espaço das variáveis de forma a minimizar uma medida de impureza, como o erro

quadrático médio em problemas de regressão. O método apresenta boa interpretabilidade e é capaz de capturar relações não lineares entre as variáveis, porém pode sofrer de sobreajuste quando a profundidade da árvore é excessiva, exigindo controle de parâmetros para garantir boa generalização.

2) *Aplicação prática e parâmetros*: O modelo foi implementado em Python, utilizando o ambiente Google Colab. As bibliotecas empregadas foram pandas para manipulação de dados, scikit-learn para criação e avaliação do modelo, matplotlib para visualização dos resultados e gdown para importação do arquivo de dados.

Para a previsão final, utilizou-se a planilha dados-previsaoParteII, contendo as mesmas variáveis preditoras, exceto a coluna de quantidade. O conjunto passou pelo mesmo processo de codificação dummy, garantindo correspondência entre as colunas do treino e da previsão. O modelo estimou a demanda diária de refeições para cada restaurante (RU, RA e RS) e refeição (almoço e jantar) nos dias úteis.

D. Regressão Binomial Negativa

1) *Aspectos teóricos*: A Regressão Binomial Negativa é um modelo estatístico indicado para dados de contagem que apresentam sobredispersão, ou seja, quando a variância é maior que a média. O modelo introduz um parâmetro de dispersão adicional em relação à regressão de Poisson, permitindo ajustar adequadamente essa variabilidade extra. A formulação teórica e os parâmetros específicos empregados serão detalhados após a implementação do modelo.

2) *Aplicação prática*: O modelo de Regressão Binomial Negativa foi implementado em R, utilizando o ambiente Google Colab. As bibliotecas empregadas foram tidyverse, para manipulação e organização dos dados, e MASS, para o ajuste do modelo estatístico. Valores ausentes (NA), bem como os registros correspondentes a sábados e domingos, foram removidos, uma vez que a previsão se restringe aos dias úteis. As variáveis tipo refeicao, restaurante utilizado, categoria padrao, categoria vegano, dia semana, mes, almoco, periodo semestre e feriado dummy foram utilizadas como preditoras, enquanto a variável resposta corresponde à quantidade de refeições servidas.

Como a variável resposta representa contagens, inicialmente considerou-se o ajuste de um modelo de Regressão de Poisson. No entanto, verificou-se a presença de superdispersão, caracterizada pela variância maior que a média, o que inviabiliza a adequação do modelo de Poisson. Para contornar esse problema, optou-se pela Regressão Binomial Negativa, que incorpora um parâmetro adicional de dispersão capaz de modelar a variabilidade extra dos dados.

Esse modelo pode ser interpretado como uma mistura das distribuições Poisson e Gama: assume-se que o número de refeições servidas segue uma distribuição de Poisson, cuja média, por sua vez, varia segundo uma distribuição Gama. Dessa forma, a heterogeneidade não observada é capturada por meio desse parâmetro adicional.

A relação entre a média (μ_i) e a variância no modelo Binomial Negativo é dada por:

$$Var(Y_i) = \mu_i + \frac{1}{\nu} \mu_i^2 = \mu_i + D \mu_i^2 \quad (1)$$

em que $D = (1/\nu)$ representa o parâmetro de dispersão. Quando $D \rightarrow 0$, a variância tende à média, e o modelo de Binomial Negativa converge para um modelo de Poisson.

O modelo ajustado possui função de ligação logarítmica, expressa como:

$$\begin{aligned} \log(\mu_i) = & \beta_0 + \beta_1(almoco)_i + \beta_2(restaurante_utilizado)_i + \\ & \beta_3(categoria_padrao)_i + \beta_4(categoria_vegano)_i + \\ & \beta_5(dia_semana)_i + \beta_6(periodo_semestre)_i + \\ & \beta_7(feriado_dummy)_i \end{aligned} \quad (2)$$

onde μ_i representa o número esperado de refeições servidas para a observação i . Esse modelo foi escolhido por sua robustez e capacidade de representar adequadamente a natureza dos dados de contagem observados neste estudo.

E. Treinamento e Teste

Para realizar o treinamento do modelo de árvore de decisões, os dados foram separados - a partir de uma semente para garantir reprodutibilidade - em quatro variáveis: X_{test} , Y_{test} , X_{train} e Y_{train} . Para essa separação, 80% do banco de dados total foi reservado ao treino (variáveis X_{train} e Y_{train}) e os 20% restantes foram alocados às variáveis de teste (X_{test} e Y_{test}). Como abordado anteriormente, a variável de interesse é a quantidade de pessoas (*quantidade*), portanto os dados desta foram alocados à variável Y , e os dados das variáveis *tipo_refeicao*, *restaurante_utilizado*, *categoria_padrao*, *categoria_vegano*, *dia_semana*, *mes*, *almoco*, *periodo_semestre*, *feriado_dummy* foram alocados de forma vetorial à variável X .

Assim, uma vez definidos os dados de treino e teste, o modelo foi treinado com profundidade 20 (*max_depth*) com as variáveis X_{train} e Y_{train} . Em seguida, o X_{test} foi utilizado para realizar a previsão da variável de interesse, nomeada de Y_{prev} .

O gráfico 1 apresenta a relação entre os valores reais e os valores previstos pelo modelo. O ideal é que os pontos estejam próximos da linha vermelha, que representa a igualdade entre valores observados e estimados. Pontos acima dessa linha indicam superestimação, enquanto os pontos abaixo indicam subestimação. De modo geral, observa-se que o modelo apresenta um desempenho satisfatório, pois as previsões estão razoavelmente próximas dos valores reais.




Gráfico 1. Comparação dos valores reais vs os valores obtidos pelo modelo de teste da Árvore de Decisão

Para realizar a avaliação do desempenho do modelo de previsão, utilizou-se o erro absoluto médio (MAE) e o coeficiente de determinação R^2 entre a variável prevista e a observação real (Y_{prev} e Y_{test}), cujos valores obtidos foram, aproximadamente,

- MAE: 240.06
- R^2 : 0.903

Embora o MAE esteja bom, ele não está ideal, dada a escala dos dados que estão sendo usados. No entanto, o coeficiente de determinação – indicador com intervalo de 0 a 1 – indica um bom ajuste do modelo de árvore de decisões aos dados.

Já para o modelo de Regressão Binomial Negativa, também foi utilizada a mesma proporção de dados para treino e para teste - 80% e 20%, respectivamente. Além disso, as mesmas variáveis de interesse foram aplicadas ao modelo, e usadas para fazer as previsões dos dados de teste.

Os resultados do treino podem ser verificados no gráfico 2, que indica que o ajuste do modelo está adequado.




Gráfico 2. Comparação dos valores reais vs os valores obtidos pelo modelo de teste da Binomial Negativa

Para avaliar seu desempenho, também foi utilizado o erro absoluto médio (MAE), mas em adição, foi o Pseudo R^2 de Nagelkerke, cujos valores obtidos foram

- MAE: 207.8943
- Pseudo R^2 de Nagelkerke: 0.8707

O pseudo R^2 é um índice que busca capturar a qualidade do ajuste, embora não seja equivalente ao coeficiente de determinação tradicional da regressão linear. Especificamente o R^2 de Nagelkerke é uma versão ajustada do índice de Cox e Snell, escalonada para ter um intervalo entre 0 e 1, e foi calculado usando o pacote DescTools do R.

Assim, pode-se inferir que, em relação ao modelo de Árvore de Decisões, este modelo tem maior acurácia ao analisarmos o MAE, no entanto a qualidade do ajuste é inferior.

III. RESULTADOS

Uma vez treinados os modelos, eles foram utilizados para realizar previsões para a semana do dia 20 de outubro de 2025, a partir do cardápio previsto. Para tanto, foi utilizado um banco contendo informações sobre as variáveis que seriam utilizadas para a previsão.

Assim, sob a suposição de que não haverão mudanças no cardápio, os resultados obtidos sobre a quantidade de pessoas em cada restaurante universitário, separado por refeição e dia da semana, se encontram nas tabelas 4 e 5:

TABELA 4
RESULTADOS DA PREVISÃO
MODELO DE ÁRVORE DE DECISÕES

Dia	Refeição	RU	RA	RS	Total
Segunda	Almoço	3190	1321	1563	6074
Segunda	Janta	2762	897	1078	4737
Terça	Almoço	2817	1166	1497	5480
Terça	Janta	2359	631	994	3984
Quarta	Almoço	1763	707	843	3313
Quarta	Janta	2588	657	834	4079
Quinta	Almoço	2908	1096	1751	5755
Quinta	Janta	1222	323	310	1855
Sexta	Almoço	2917	1011	1108	5090
Sexta	Janta	1637	440	382	2063

TABELA 5
RESULTADOS DA PREVISÃO
MODELO DE REGRESSÃO BINOMIAL NEGATIVA

Dia	Refeição	RU	RA	RS	Total
Segunda	Almoço	3360	1007	980	5347
Segunda	Janta	1816	544	530	2890
Terça	Almoço	3324	997	970	5291
Terça	Janta	1904	571	556	3031
Quarta	Almoço	2017	605	589	3211
Quarta	Janta	1729	518	505	2752
Quinta	Almoço	3769	1130	1100	5999
Quinta	Janta	1013	304	296	1613
Sexta	Almoço	2785	835	813	4433
Sexta	Janta	1397	419	408	2224

A representação visual da diferença entre os resultados obtidos em cada modelo se encontra nos gráficos 3 e 4, como segue:




Gráfico 3. Quantidade prevista de refeições

Ao analisar o Gráfico 3 e as tabelas com as previsões, é possível perceber que nos dois modelos de previsão, o RU concentra a maior quantidade de pessoas, e os outros dois restaurantes possuem quantidades bem menores. Apesar da diferença volumétrica, a previsão realizada indica que o comportamento diário tende a ser parecido entre os dias da semana, com picos e vales em lugares similares em cada restaurante, por dia.

Para abordar melhor as diferenças entre cada modelo, construiu-se o gráfico que representa o percentual da diferença absoluta entre a previsão de cada modelo, também separada por restaurante e refeição:




Gráfico 4. Percentual da diferença absoluta da quantidade prevista entre os modelos

Para explicar melhor, este gráfico foi construído de forma que, para cada dia da semana, restaurante e refeição, a observação foi calculada realizando a diferença absoluta entre a previsão de cada modelo, dividida pela média das quantidades previstas em cada modelo, ou seja:

$$dif = \left| \frac{Q_{arv} - Q_{reg}}{\frac{Q_{arv} + Q_{reg}}{2}} \right| \quad (3)$$

Onde Q_{arv} e Q_{reg} representam as quantidades previstas dos modelos de Árvore de Decisão e Regressão Binomial Negativa, respectivamente.

Assim, pode-se concluir que, apesar de existir um comportamento similar entre modelos, ainda existem pontos que se mostram bastante distintos, como as quantidades previstas para o RS por exemplo.

IV. CONCLUSÃO E PRÓXIMOS PASSOS

O presente trabalho teve como propósito principal avaliar o desempenho de dois algoritmos de aprendizado supervisionado — Árvore de Decisão e Regressão Binomial Negativa — na previsão da demanda diária de refeições servidas nos restaurantes universitários da Unicamp. A comparação entre ambos permitiu identificar suas potencialidades e limitações frente ao problema proposto, considerando tanto aspectos de acurácia quanto de interpretabilidade dos modelos.

De maneira geral, os resultados indicam que ambos os modelos apresentaram desempenho satisfatório, sendo capazes de capturar o comportamento padrão do consumo de refeições ao longo da semana. O modelo de Árvore de Decisão demonstrou maior capacidade explicativa, com coeficiente de determinação elevado e boa adequação às variações observadas nos dados. Já a Regressão Binomial Negativa apresentou menor erro médio absoluto, mostrando-se mais robusta na predição de contagens e confirmando sua adequação a dados com sobredispersão.

Essas análises contribuem diretamente para o objetivo do estudo, ao oferecer uma ferramenta preditiva que pode subsidiar o planejamento operacional dos restaurantes universitários, reduzindo o desperdício de alimentos e promovendo o uso mais racional dos recursos.

Como continuidade deste trabalho, serão utilizados métodos de aprendizado de máquina não supervisionado com a finalidade de proporcionar dias representativos de consumo, ou seja, dias com perfis parecidos de consumo.